



Güney
Çelik

PROJE KONUSU: YAPAY ZEKA İLE ÇİVİ KALİTE KONTROLÜ

PROJE NO:

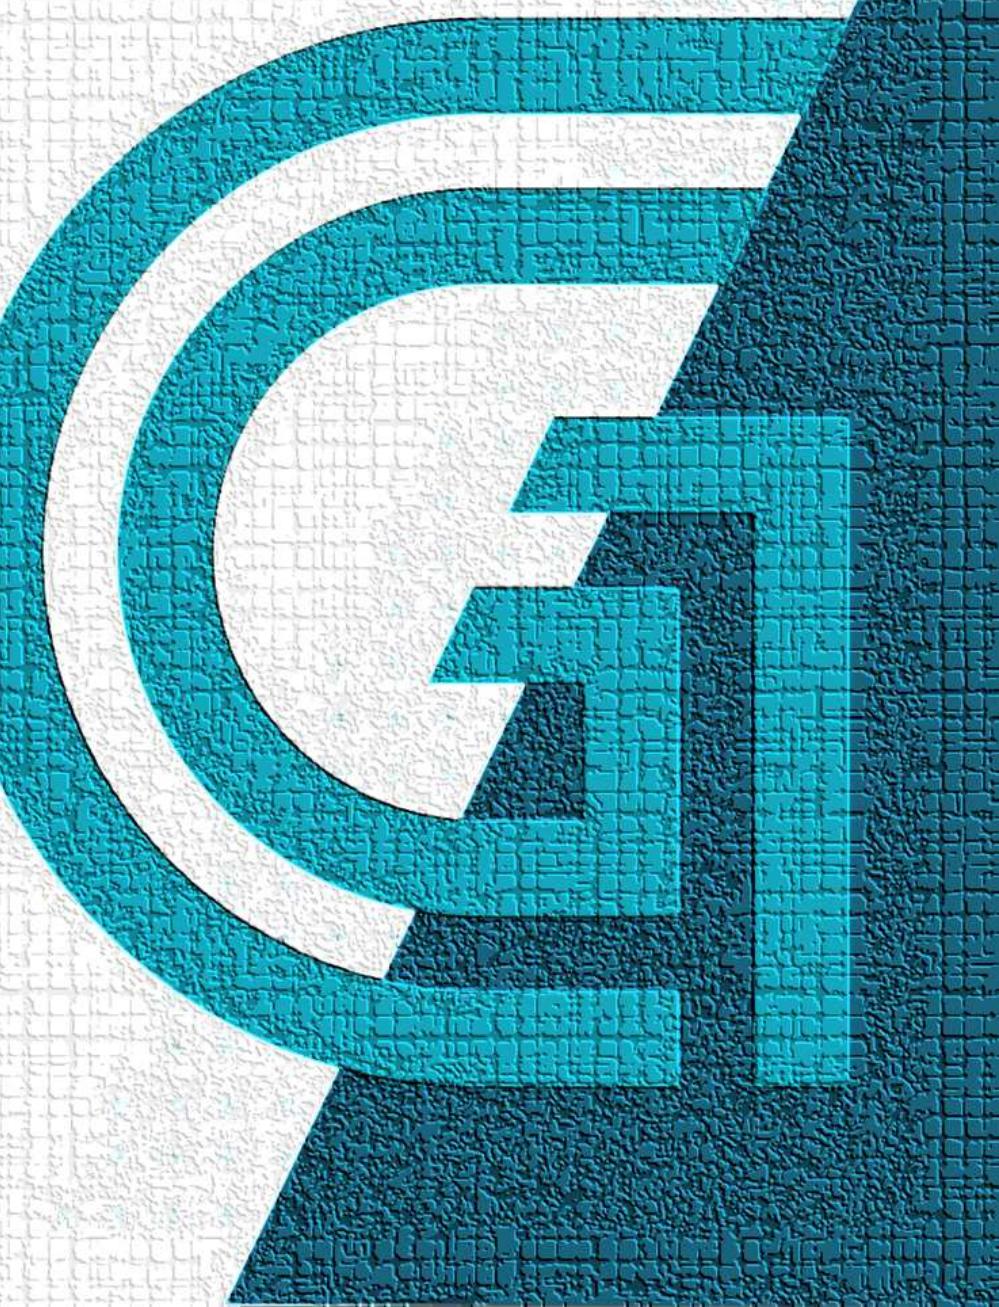
BAŞLAMA-BİTİŞ TARİHLERİ:





SUNUM İÇERİĞİ

- 1- Proje Konusu Ve İçeriği**
- 2- Projeyi Belirleyen İhtiyaçlar**
- 3- Proje Kapsamında Yapılacak Faaliyetler**
- 4- Projenin Yenilikçi Yönü ve Ar-Ge Niteliği**
- 5- Projenin Beklenen Çıktı Ve Faydaları**



Projedeki ilerleyiş

1. Adım

Projeyi Belirleyen İhtiyaçlar

Problemin çözüm üretilibilecek açıdan tam kavranması.

2. Adım

Mevcut Durum Analizi

Ana problem ışığında olası çözümün bulunması

3. Adım

Çözüm Analizi

Çözümün maaliyet ve verimlilik açısından analizinin gerçekleştirilmesi

4. Adım

Projeye Giriş

Projenin yapılabılırlığının anlaşılmasıının ardından gerçek zamanlı çalışmalara başlanması

5. Adım

Projenin Geliştirilmesi

Projenin verimliliğinin artırılıp aktif olarak kullanılabilir hale getirilmesi

Projeyi Belirleyen İhtiyaçlar

Güney Çelik Hasır A.Ş olarak 2019 yılında CIVIDA marka galvanizli çivi üretimine başlandı. Firmamızda çivi üretimi tele dizili çivi, kâğıda dizili çivi, plastigé dizili çivi ve dökme çivi şeklindedir. Bu civilerin tele, kağıda ve plastigé dizilişi sırasında veya dökme çivi üretiminde çivi kusurlarından dolayı kalite problemleri ortaya çıkmaktadır.

Problemlerden bazıları:

- Kesme makinalarında civiler tel halinden ayrıılır
- Çıkan civiler dizgi makinasına geçer

Civilerin üretim aşamasında kusurlu halleri de bulunmakta, bu bağlamda çıkan sorunlar:

- Makinanın çok durmasından dolayı hurda kullanımının artması
- Çivi üretimi sırasında kalıp ayarlarının bozulması
- Çivi üzerindeki yağlayıcının kalıplara yapışmasından dolayı kalıpların zarar görmesi
- Çivi boyalarında kısalma, çivi uç kısımlarında kesme açılarının farklılık göstermesi
- Çivi baş kısmının deform olması

Belirtilen üretim sırasında oluşabilecek bu problemlerin 7 gün 24 saat çalışan bir sistemde operatöre bağlı olarak yeterli düzeyde kontrol edilmesi mümkün gözükmektedir. Çünkü çivi üretiminin çok hızlı ve sürekli akış halinde olması sebebiyle üretim operatörleri ve kalite kontrol operatörleri tarafından kontrol edilmesi neredeyse imkânsızdır. Bunun sebebi mevcutta bulunan birçok çivi makinesinin sürekli aynı anda çalışmasıdır. Dolayısıyla çivinin üretim işlemi sürekli olduğundan, operatörlerin de her bir çivi makinesinin başında sürekli beklemesi imkânsızdır. Bu sebeple çivi üretim sırasında üretim hatalarından dolayı firmada manevi ve maddi kayıplar söz konusudur. Maddi olarak yıllık yaklaşık 80 ton, bu tonaja karşılık gelen 80.000,00 \$ gibi ticari kayıplar söz konusudur. Hem sürdürülebilir bir üretim kalitesine sahip olmak hem de operatörden bağımsız çivi üretiminde kusurlu ürünlerin tespiti için yapay zekâyla görüntü işleme yöntemini kullanarak çivi üretimi sırasında karşılaşılan problemlerin önüne geçmek hedeflenmiştir.

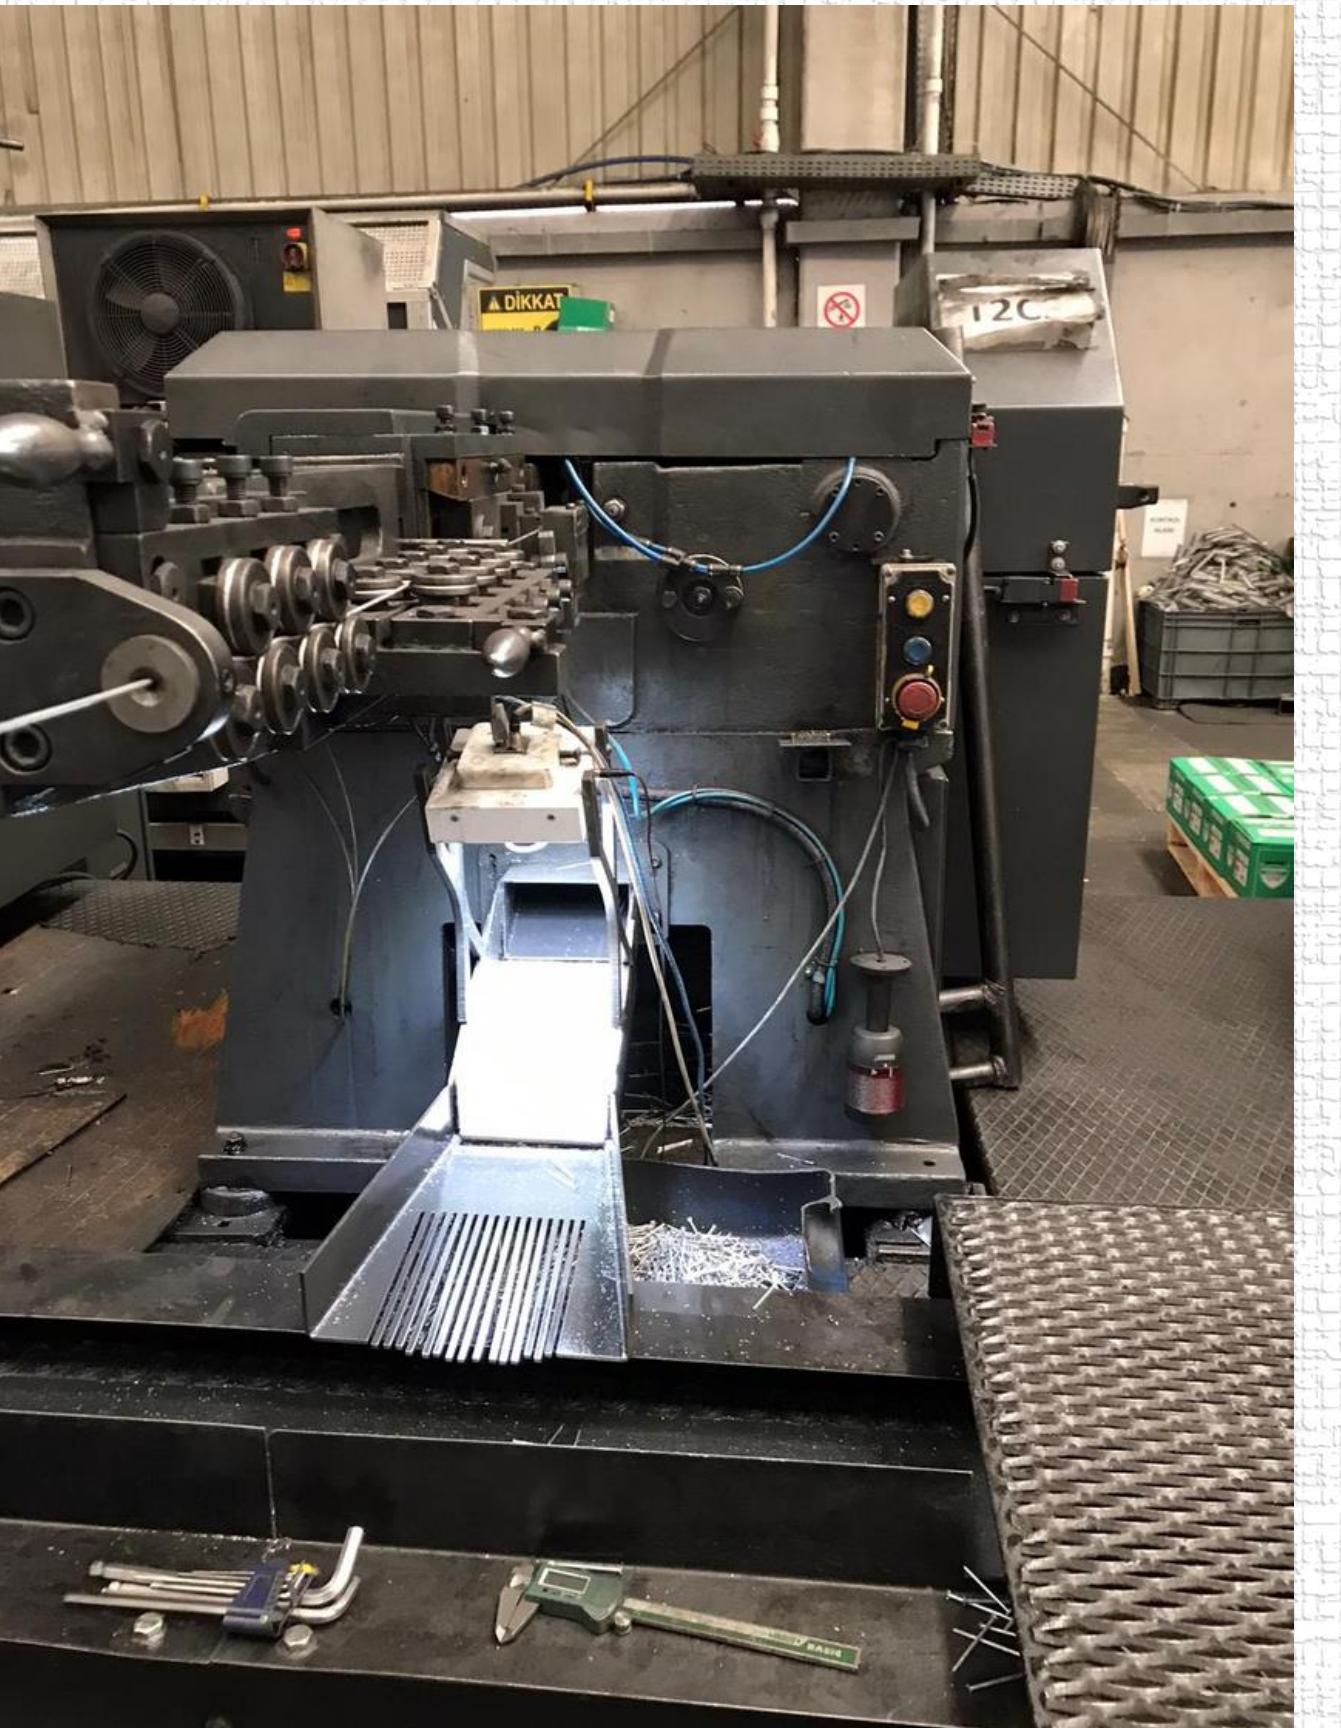
Görseller



Projeye Kapsamında Yapılacak Faaliyetler

İhtiyaçlar ışığında sahadaki makinaların takibinin ve bununla beraber çivilerin kusurlarının tespitinin yapılması gereklidi.

- Çivilerin aktığı hizaya kamera sisteminin kurulması,
 - Uygun kamera seçimi (yüksek fps li monochrome global shutter) için testler yapılması.
 - Kameranın odak uzaklığı ile focal lenght hesabının yapılması ve yüzeyde 60 derecelik bir açıyla bakış sağlanarak mekanik tripot tasarımının yapılması.
- Makina ile ana bilgisayarın görüntü alabilecek şekilde iletişiminiin sağlanması,
- Makinada görüntü işleme ile başarılı bir kusurlu çivi tespiti yapan model oluşturulması,
- Makinalara çivi tespit sisteminin otomasyon kısmının yapılması: alarm sistemi ile dakikada 3 yamuk çivi gelmesiyle makinenin durdurulması ve operatörün sorunu gidermesi,



Yanda sahadaki çivi kesme makinalarından biri gösterilmiştir. Görseldeki ürünler:

- Basler Lens C23-0816-2M-S f8mm Lensi
- Basler acA1440-73gm kamera
- Işıklı alarm sistemi
- Fiber bağlantı (10G)

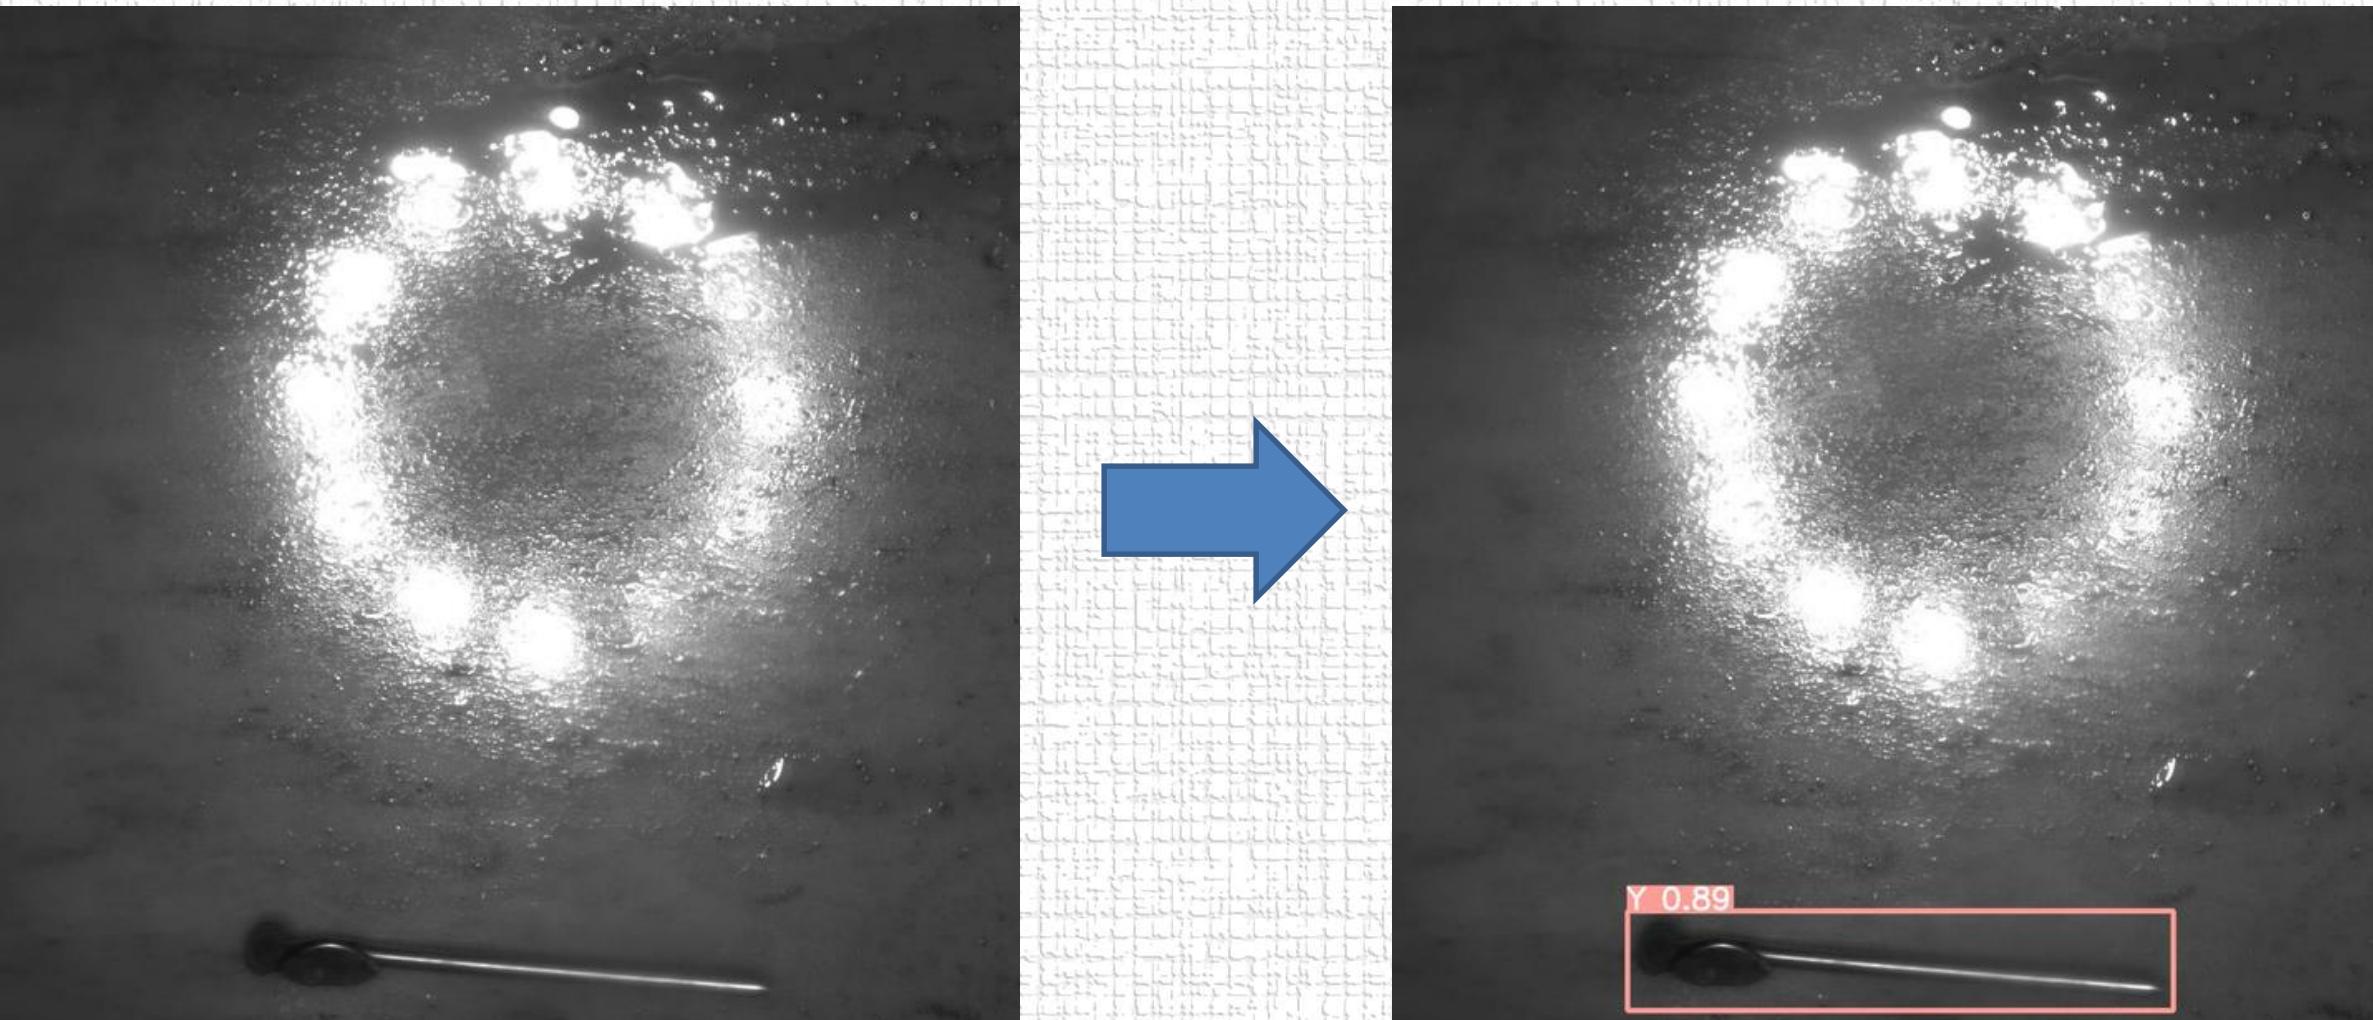


Basler acA1440-73gm kamera mono çekim sağlamaktadır. Normal kameraların aksine görüntüyü yakalamak için farklı renkleri değil farklı miktarda ışık kullanan endüstriel bir kameradır



Basler Lens C23-0816-2M-S f8mm lens, diyafram açığını ve odak ayarını yaparak kameranın aldığı görüntüyü daha işlenebilir hale getirmeyi sağlamaktadır. Diyafram açığı ışığı toplayacağı açıyı sembollerken odak ayarı da netliğini sembollemektedir.

Sahadaki makinadan gelen veriler ana bilgisayarda işlenmektedir. Ana makinada YOLOV5 ile geliştirilmiş olan bir nesne algılama işlemi yapan yapay zeka modeli bulunmaktadır. Bu yapay zeka modeli civilerin kusurlu olup olmadığını tespit etmektedir. Yapay zeka modelimizin dönütüne göre veritabanındaki ışıkları içeren veri tablosunda anlık değişimler yapıp sahadaki alarm ışıklarını yakmaktadır. Aşağıda modelimize gelen bir fotoğraf ve yapay zeka modelimizin bize verdiği sonuç görülmektedir.



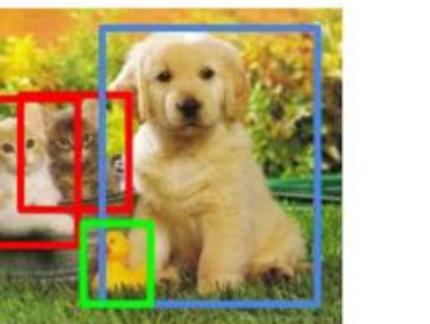
Nesne Algılama Nedir?

Classification



CAT

Object Detection



CAT, DOG, DUCK

Instance Segmentation



CAT, DOG, DUCK

Nesne Algılama Nedir?

Nesne algılama, dijital görüntülerde ve videolarda belirli bir sınıftaki (insanlar, binalar veya arabalar gibi) semantik nesnelerin örneklerini algılamayla ilgilenen, bilgisayarla görme ve görüntü işleme ile ilgili bir bilgisayar teknolojisidir.

Nesne algılama ile ilgili bazı uygulamalar:

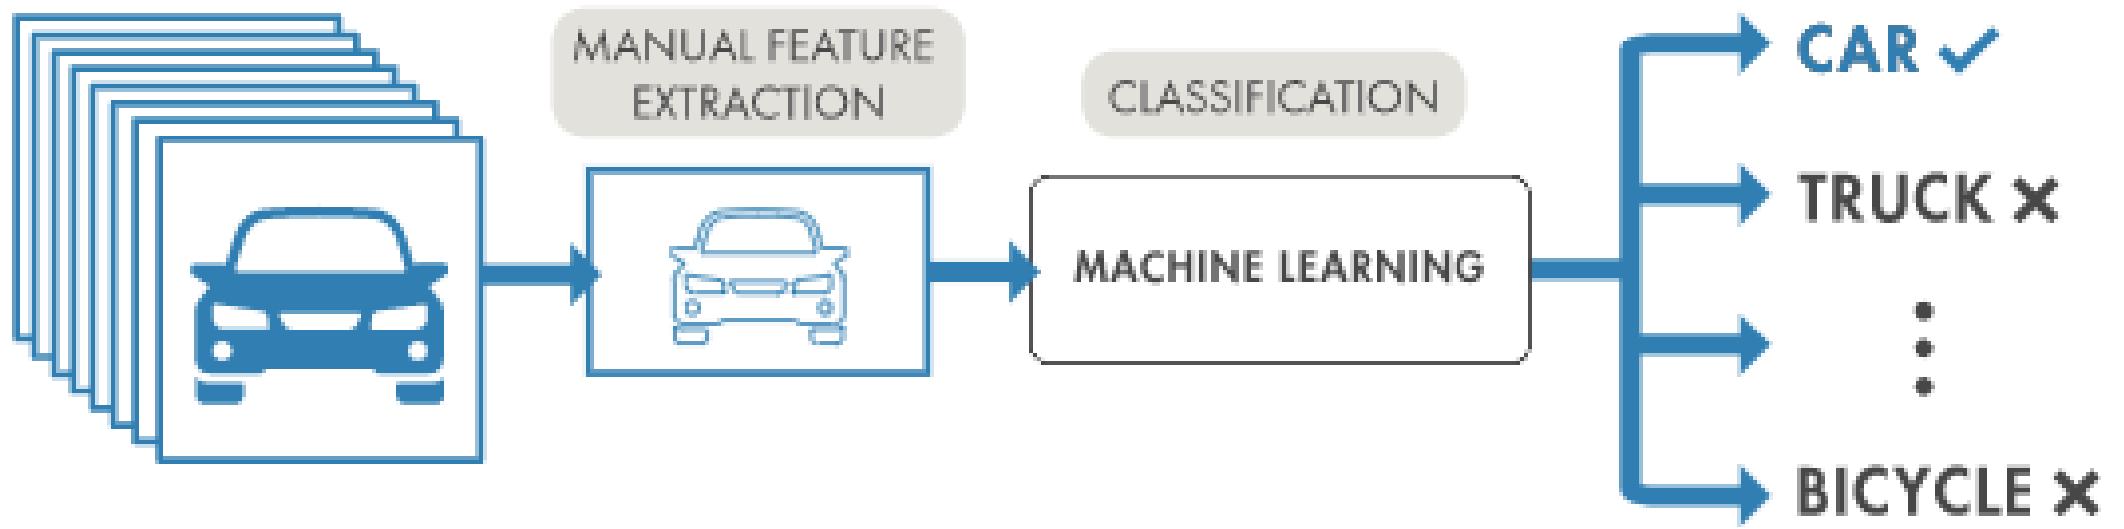
- Görüntü açıklama
- Araç sayma
- Aktivite tanıma
- Yüz algılama
- Yüz tanıma
- Nesne takibi (Futbol topu)

Makine Öğrenmesi ve Derin Öğrenmeye Dayalı Nesne Algılama

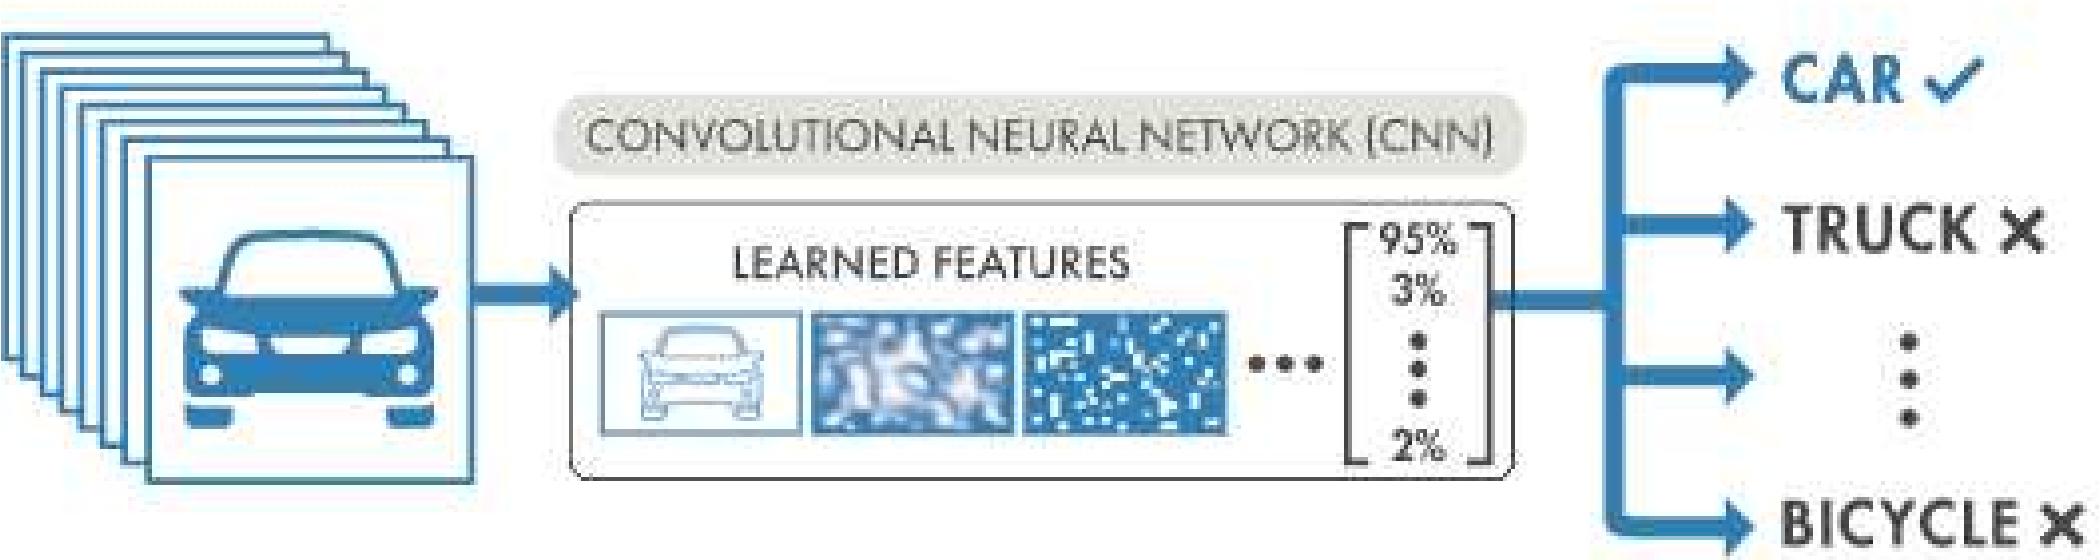
Makine öğrenimi tabanlı nesne algılama yöntemi, görüntü tabanlı özellik çıkarma tekniğini kullanarak özelliği manuel olarak çıkarmalıdır. Örneğin, histogram of oriented gradients(HOG), speeded-up robust features(SURF), local binary patterns (LBP), haar wavelets, color histograms.

Derin öğrenme tabanlı nesne algılama yöntemi, görüntünden kenar, şekil vb. gibi özellikler üreten Convolution Neural Network, Auto-Encoder, Variance Auto-Encoder vb. derin öğrenme algoritmaları yardımıyla özelliği otomatik olarak çıkarabilme özelliğine sahiptir.

MACHINE LEARNING



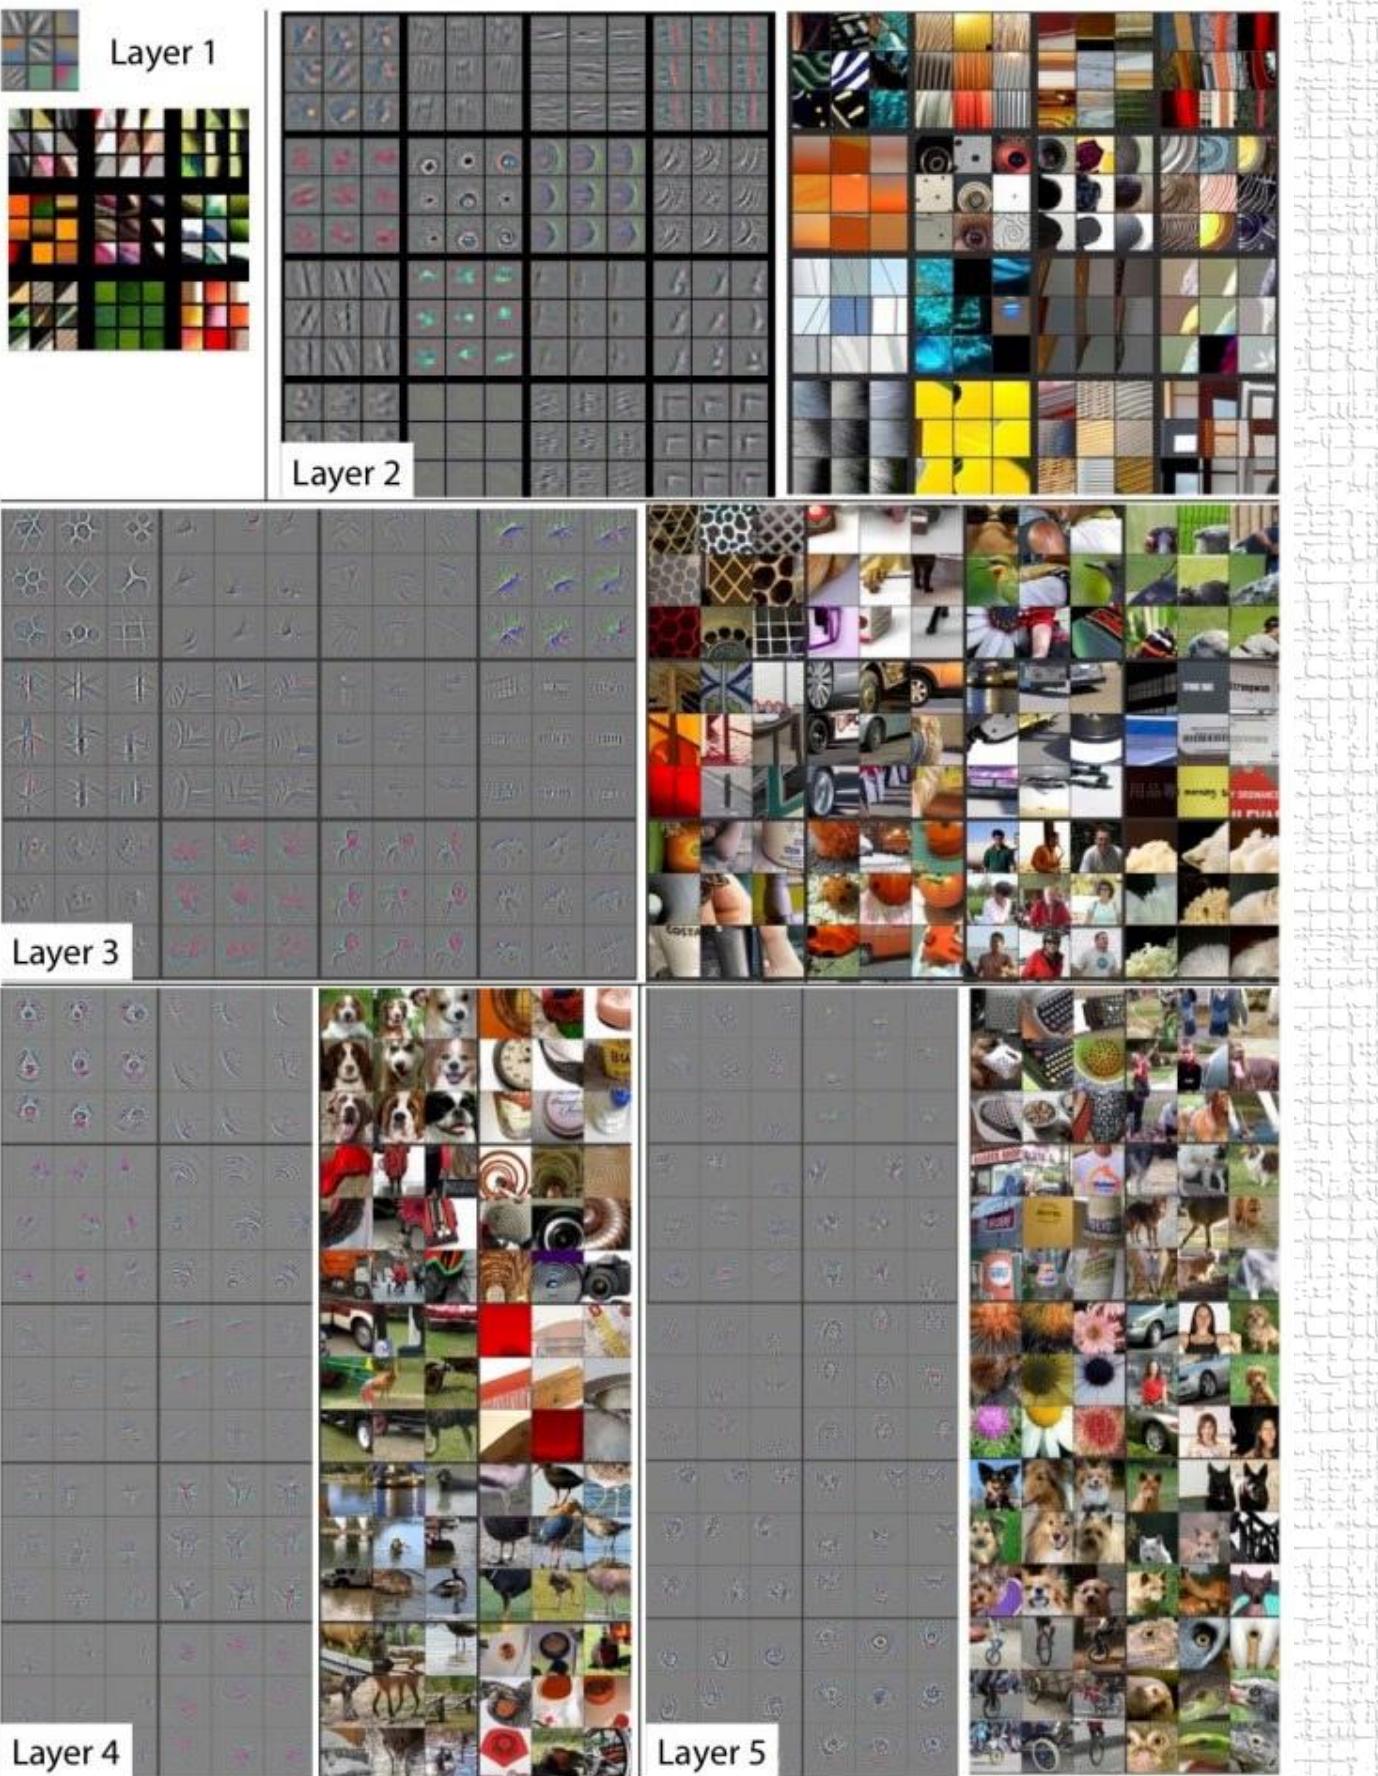
DEEP LEARNING



Evrişimli Sinir Ağları

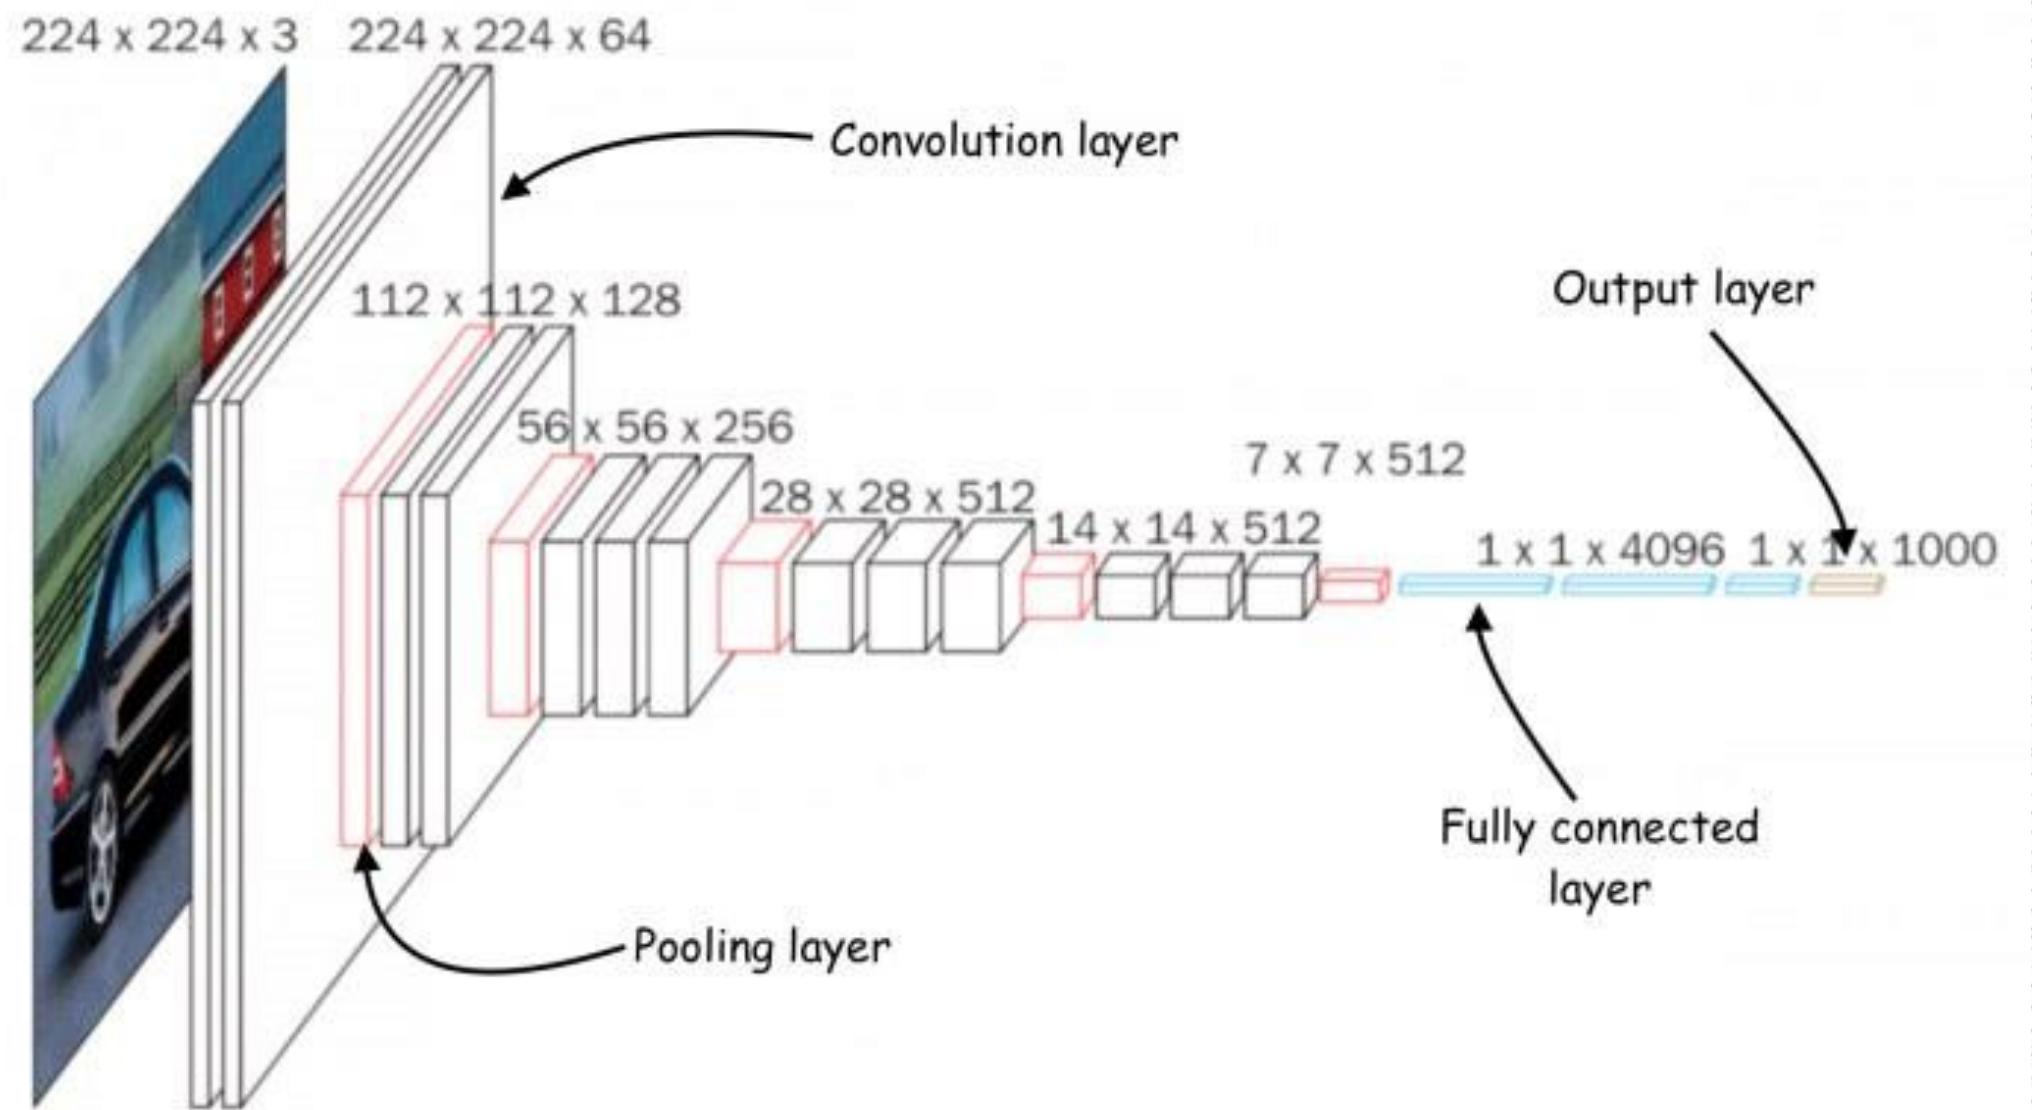
Derin öğrenme tabanlı bilgisayarlı görme uygulamalarının çoğunun temel bileşenlerinden biri evrişimli sinir ağıdır (CNN). 1980'lerde derin öğrenme öncüsü Yann LeCun tarafından icat edilen CNN'ler, çok boyutlu alanlarda kalıpları yakalamada verimli olan bir tür sinir ağıdır.

- Görüntüler için iyi yapar.
- Giriş görüntüsünden anlamlı değerler çıkarmaya yarayan katmanlardan oluşur.
- Görüntü boyunca kayan ve farklı konumlardaki ağırlıklı piksel değerleri toplamını kaydeden filtreden ve matrislerden oluşur.
- Her filtrenin farklı değerleri vardır ve giriş görüntüsünden farklı özellikler çıkarır. Bir evrişim katmanının çıktısı, bir dizi "özellik haritası"dır.
- Üst üste istiflendiğinde, evrişimli katmanlar bir görsel desen hiyerarşisini algılayabilir



Son olarak, evrişim katmanlarının çıktısı, görüntüde yer alan özelliklerin sayısal temsili olan tek boyutlu bir matrise dönüştürülür. Bu matris daha sonra özellikleri aşdan beklenen çıktı türüyle eşleştirilen bir dizi "tamamen bağlı" yapay nöron katmanına beslenir.

Output layer, çıktı olarak hedeflediğiniz sınıf sayısı kadar çıktıya eşittir



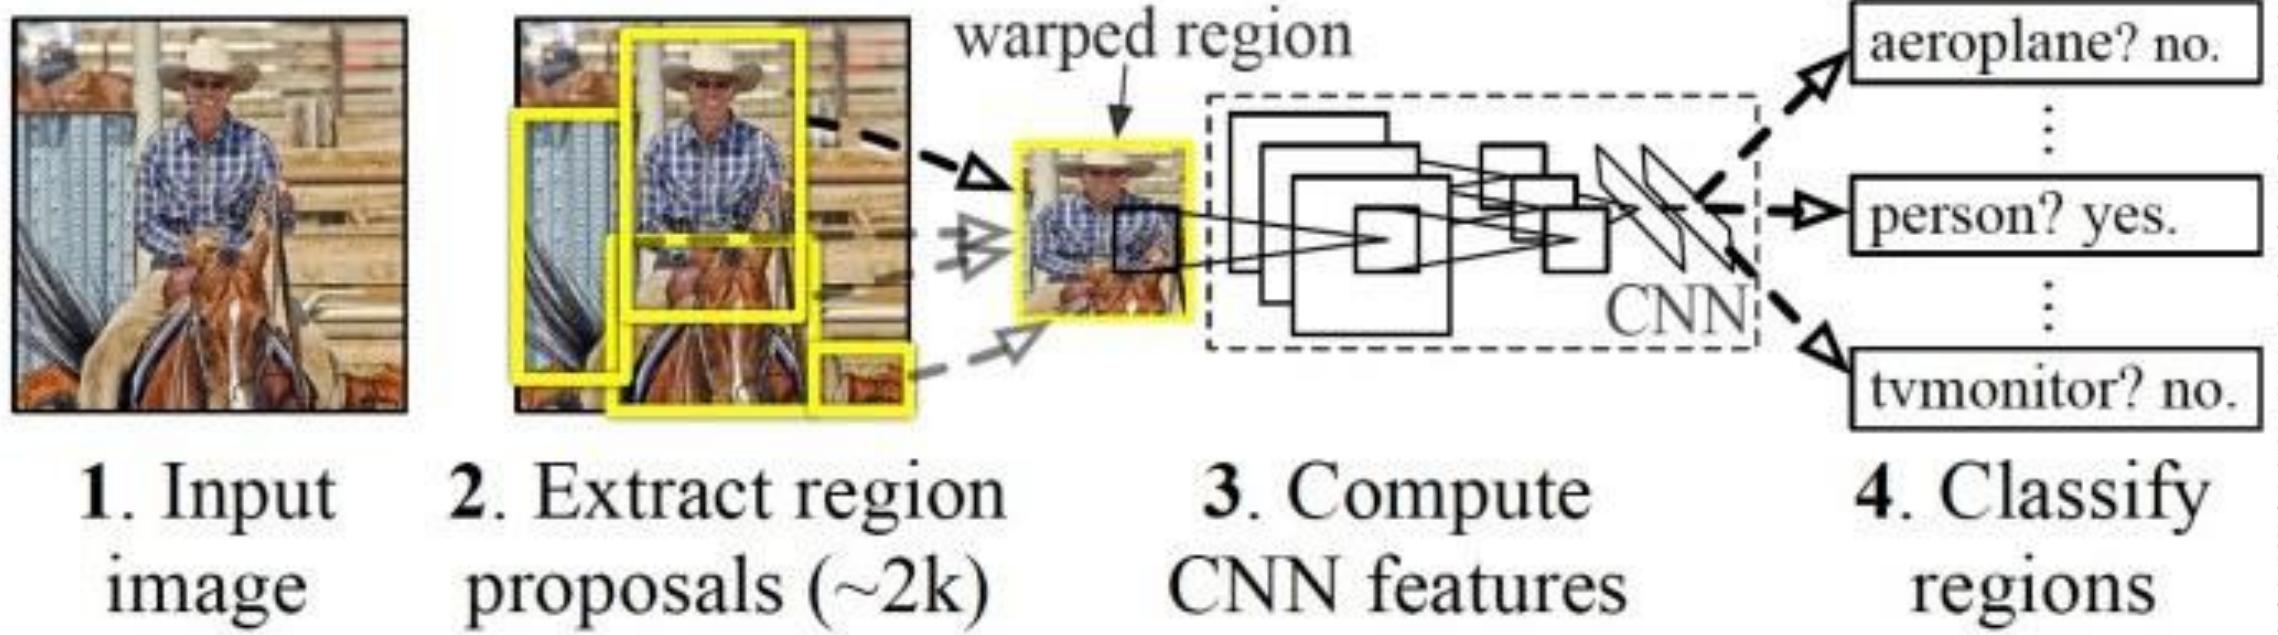
Yapay Zeka ile Görüntü İşlemede Kullanılabilecek Methodlar

2 farklı detector sistemi var; two-stage detector, one-stage detector.

Two-stage detector: Yerelleştirme ve sınıflandırma işlemini ayrı iki operasyon olarak ele alır.(R-CNN, Fast-RCNN, Faster-RCNN, FPN(Feature Pyramid Network))

One-stage detector: Tek bir geçiş ile tüm operasonları gerçekleştirir.(YOLO, SSD, DetectNet)

R-CNN Derin Öğrenme Modeli



Bölge tabanlı Evrişimsel Sinir Ağı (R-CNN), 2014 yılında California Üniversitesi, Berkley'deki AI araştırmacıları tarafından önerildi. R-CNN, üç temel bileşenden oluşur.

Seçici arama (Selective search) algoritmasını kullanarak her görüntü için yaklaşık 2.000 ilgi alanı oluşturur ve buna “ilgi bölgeleri” (RoI) da denir.

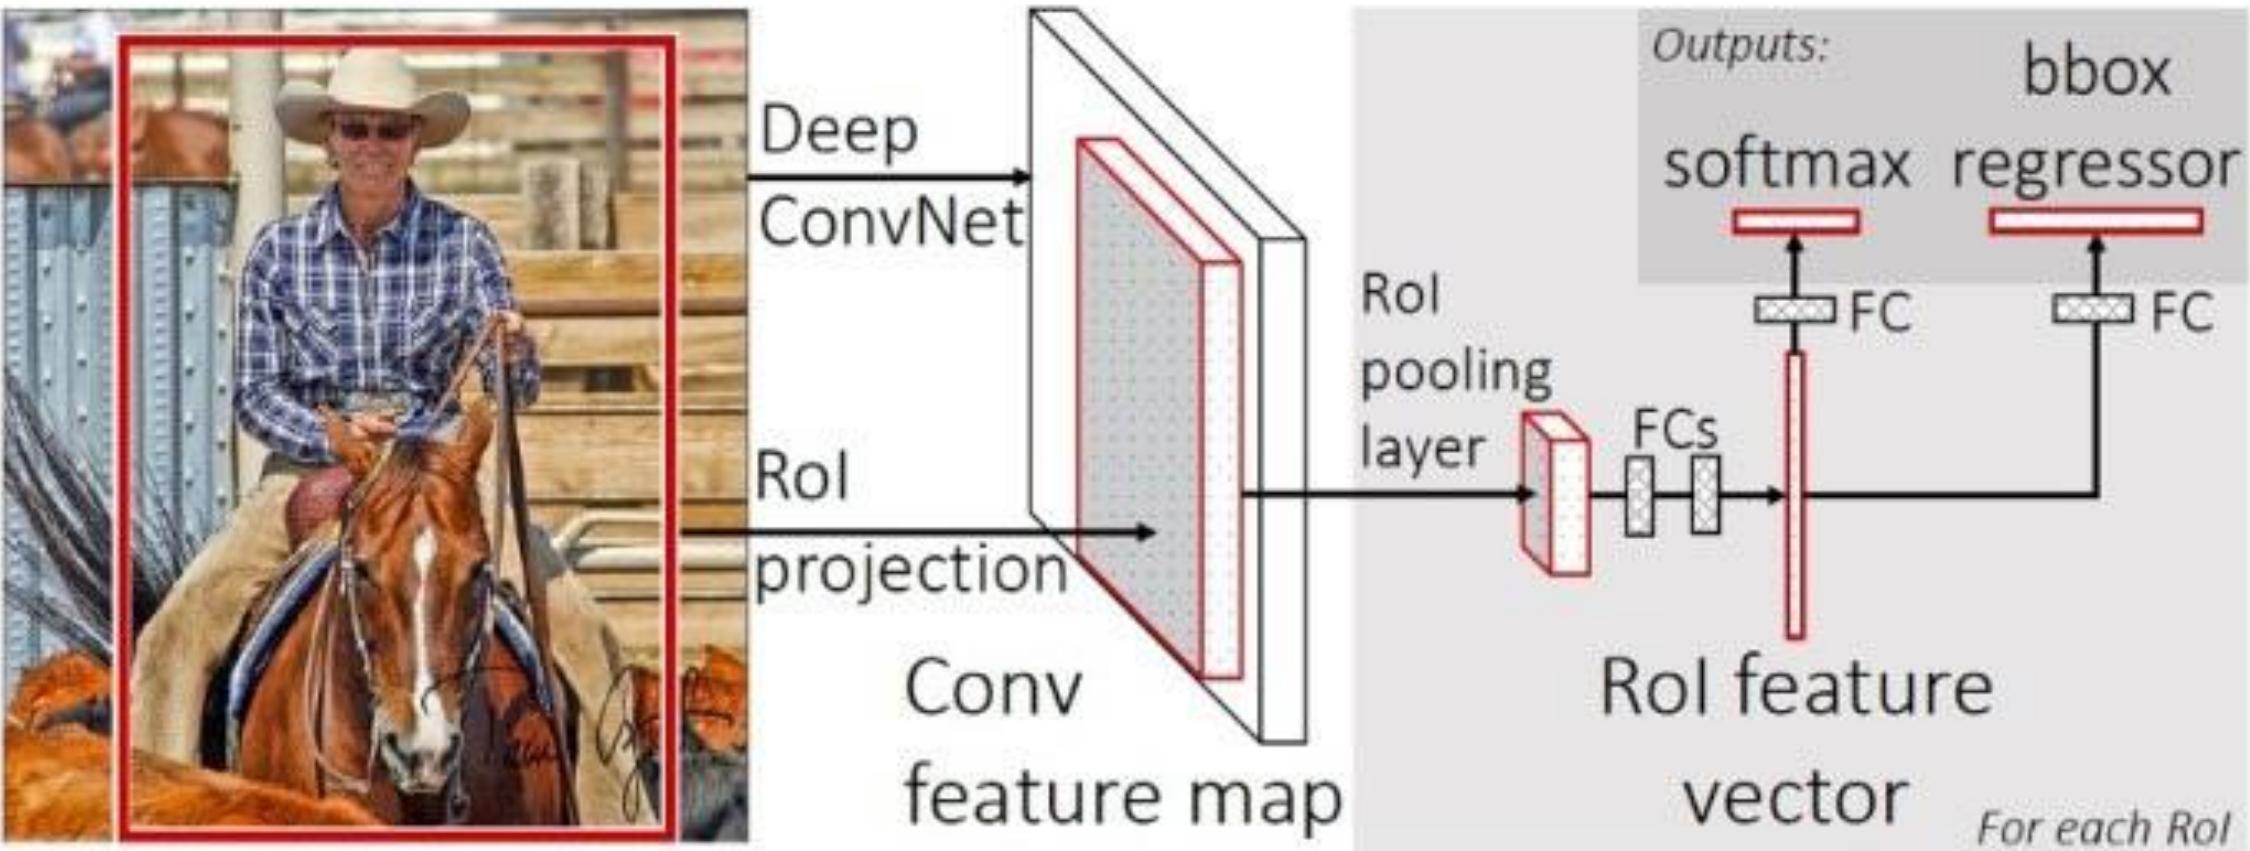
Rol'ler önceden tanımlanmış bir boyuta büükülür ve evrişimli bir sinir ağına iletılır. CNN, her bölgeyi ayrı ayrı işler ve bir dizi evrişim işlemi yoluyla özellikleri çıkarır. CNN, özellik haritalarını (Feature maps) tek boyutlu sayısal değerler vektörüne kodlamak için tamamen bağlantılı katmanlar (Fully connected layer) kullanır.

Son olarak çıktı sınıflarına eşleştirilir. Sınıflandırıcının, nesne olmayan her seye karşılık gelen "arka plan" için ayrı bir çıktı sınıfı vardır. R-CNN katman olarak özellik çıkarması (Feature Extraction) için AlexNet evrişimli sinir ağını, sınıflandırma için bir destek vektör makinesini (SVM) önerir.

R-CNN Dezavantajları:

- Zaman (Bölge önerisinden dolayı)
- Gerçek zamanlıdaki yavaşlığı (Her bir bölgeye ayrı hesaplamadan dolayı)

Fast R-CNN Derin Öğrenme Modeli



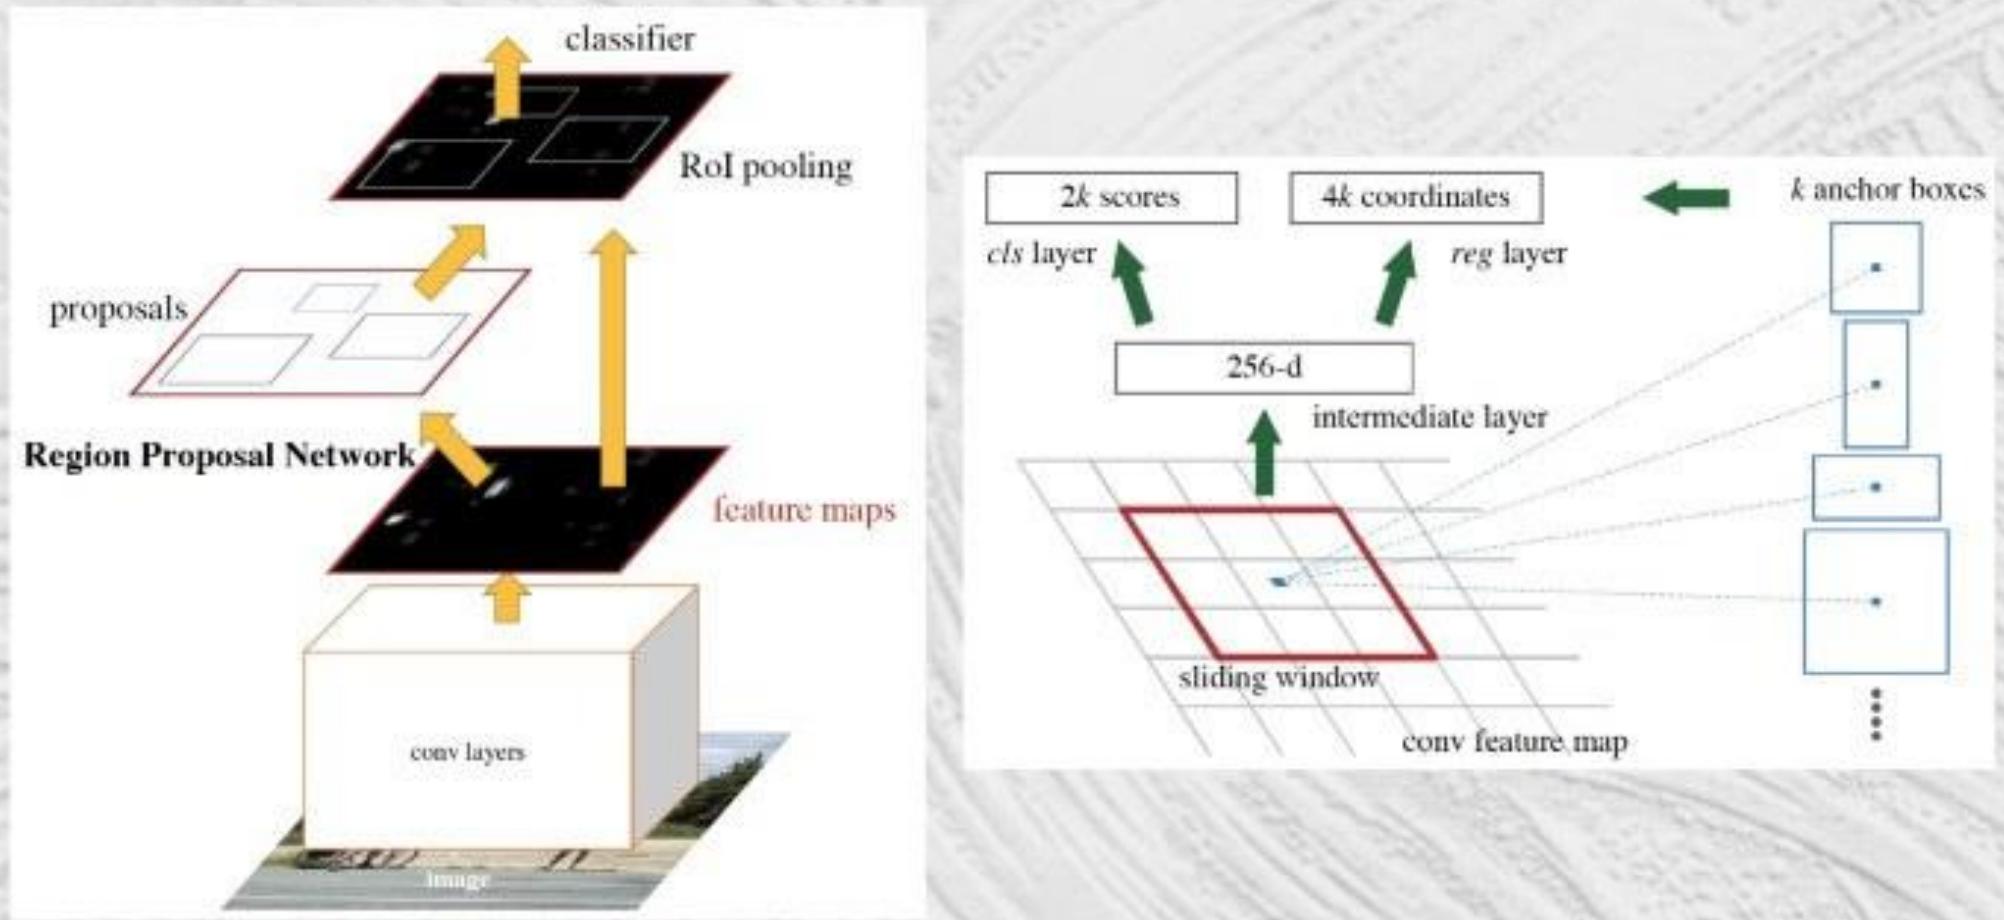
2015 yılında, R-CNN makalesinin baş yazarı, öncekinin bazı sorunlarını çözen Fast R-CNN adlı yeni bir mimari önerdi. Fast R-CNN, özellik çıkarma ve bölge seçimini tek bir makine öğrenimi modeline getiriyor.

Hızlı R-CNN, bir görüntü ve bir dizi RoI alır ve görüntüde algılanan nesnelerin sınırlayıcı kutularının ve sınıflarının bir listesini döndürür.

Fast R-CNN'deki en önemli yeniliklerden biri, bir görüntü için CNN özellik haritalarını ve ilgi alanlarını alan ve her bölge için karşılık gelen özellikleri sağlayan bir işlem olan "Röl havuzlama katmanı" idi. Bu, Fast R-CNN'nin, her bölgeyi ayrı ayrı işleyen R-CNN'nin aksine, görüntüdeki tüm ilgilenilen bölgeler için özellikleri tek bir geçişte çıkarmasına izin verdi. Bu, hızda önemli bir artışa neden oldu.

Ancak bir sorun çözülmeden kaldı. Fast R-CNN, hala görüntünün bölgelerinin çıkarılmasını ve modele girdi olarak sağlanması gerektiğini gerektiriyordu. Fast R-CNN, gerçek zamanlı nesne tespiti için hala hazır değildi.

Faster R-CNN Derin Öğrenme Modeli



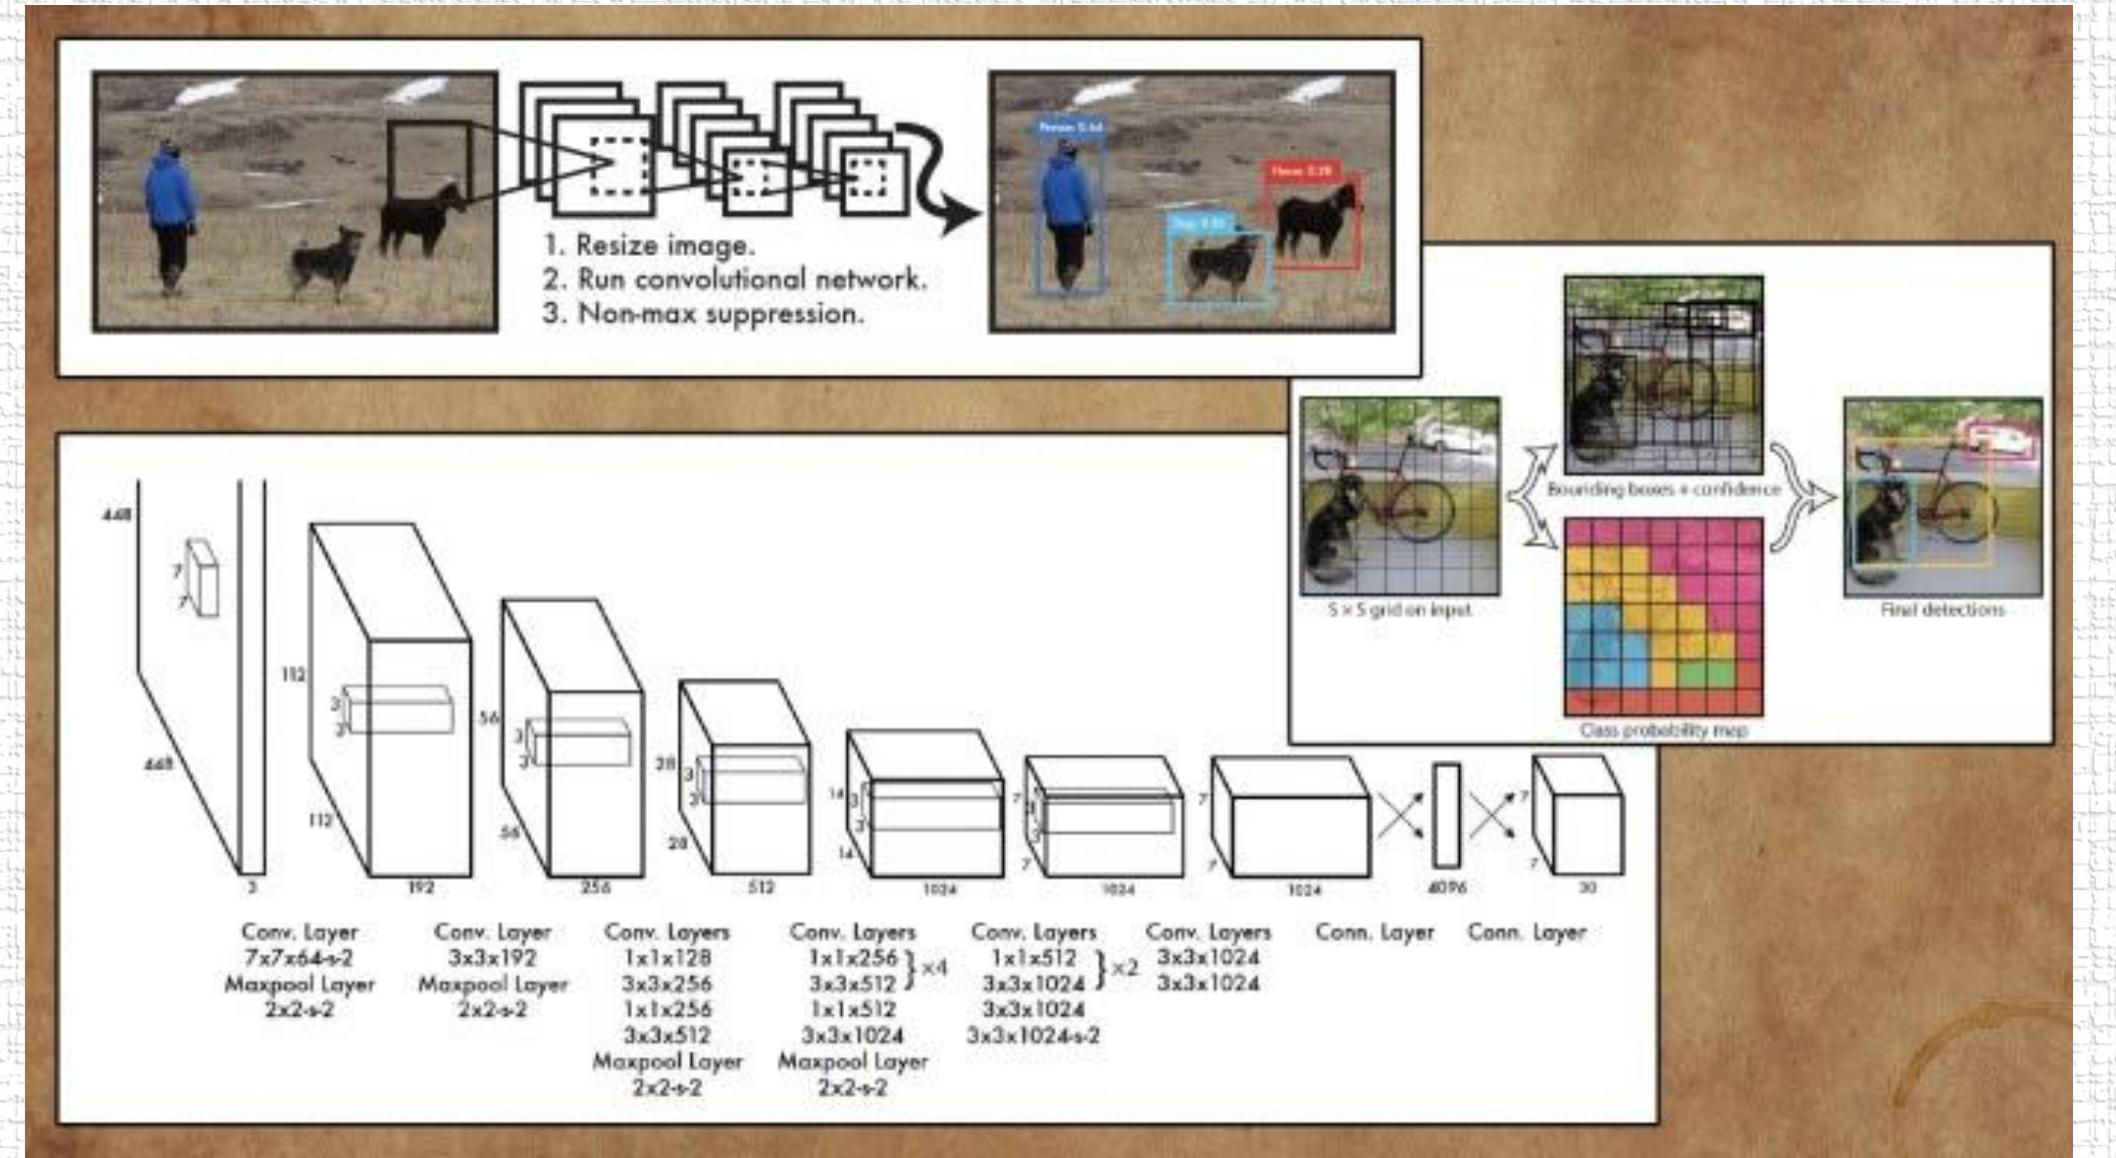
2016'da tanıtılan daha hızlı R-CNN, bölge çıkarma mekanizmasını nesne algılama ağına entegre ederek nesne algılama bulmacasının son parçasını çözüyor.

Daha hızlı R-CNN, girdi olarak bir görüntü alır ve nesne sınıflarının bir listesini ve bunlara karşılık gelen sınırlayıcı kutuları döndürür.

Faster R-CNN'nin mimarisi, Faster R-CNN'ninkine büyük ölçüde benzer. Ana yeniliği, evrişimli bir sinir ağı tarafından üretilen özellik haritalarını alan ve nesnelerin yerleştirilebileceği bir dizi sınırlayıcı kutu öneren bir bileşen olan “bölge teklif ağı” (RPN) 'dir. Önerilen bölgeler daha sonra Rol havuzlama katmanına geçirilir. Sürecin geri kalanı Fast R-CNN'ye benzer.

Faster R-CNN, bölge algılamayı ana sinir ağı mimarisine entegre ederek, neredeyse gerçek zamanlı nesne algılama hızına ulaşır.

You Only Look Once (YOLO)

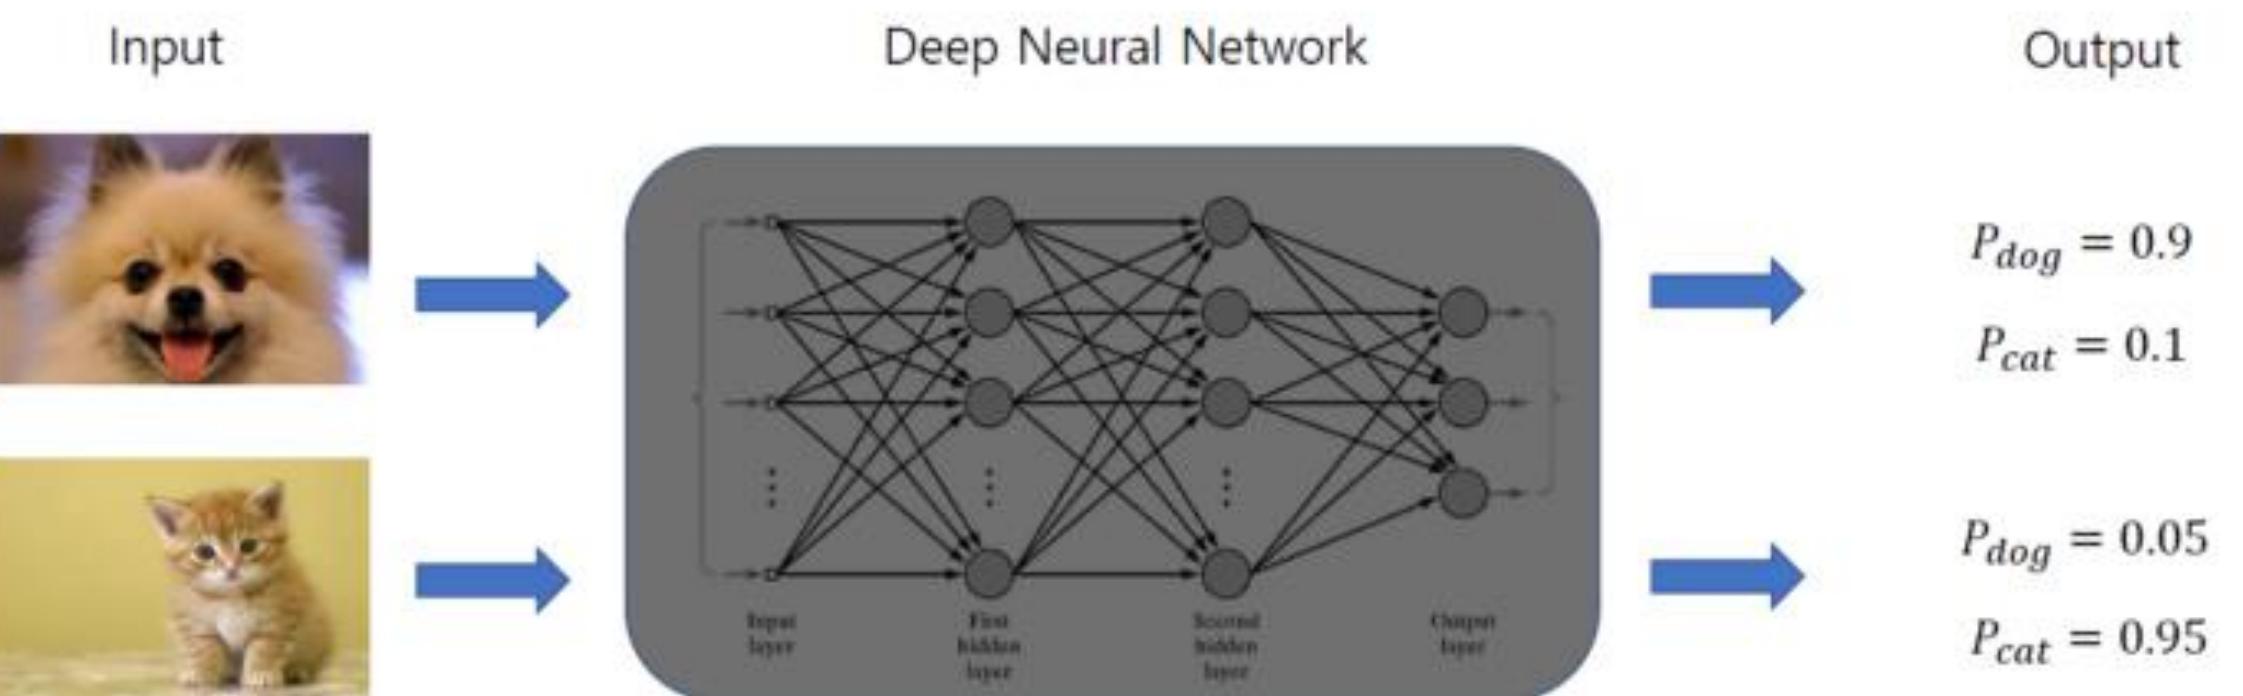


2016 yılında Washington Üniversitesi, Allen Yapay Zeka Enstitüsü ve Facebook Yapay Zeka Araştırması araştırmacıları, derin öğrenme ile nesne algılamanın hızını ve doğruluğunu artıran bir sinir ağları ailesi olan “Yalnızca Bir Kez Bakarsınız”ı (YOLO) önerdiler.

- Tüm nesne algılama ve sınıflandırma sürecinin tek bir ağda entegrasyonudur.
- Video akışı kare hızlarında nesne algılama gerçekleştirebilir ve gerçek zamanlı çıkışım gerektiren uygun uygulamalardır.
- Telefonunuzda, bilgisayarınızda, arabanızda, kameranızda ve daha fazlasında bulunabilir.

Nasıl Çalışır

Nesne algılamayı keşfetmeden önce, görüntü sınıflandırmasını bilmemiz gereklidir. Bir görüntü CNN'ye girdi olduğunda, görüntüye karşılık gelen sınıfın sınıflandırılması sorunu görüntü sınıflandırması olarak bilinir ve hedeflenen tüm sınıflar için olasılık değerleri çıktılarıdır.

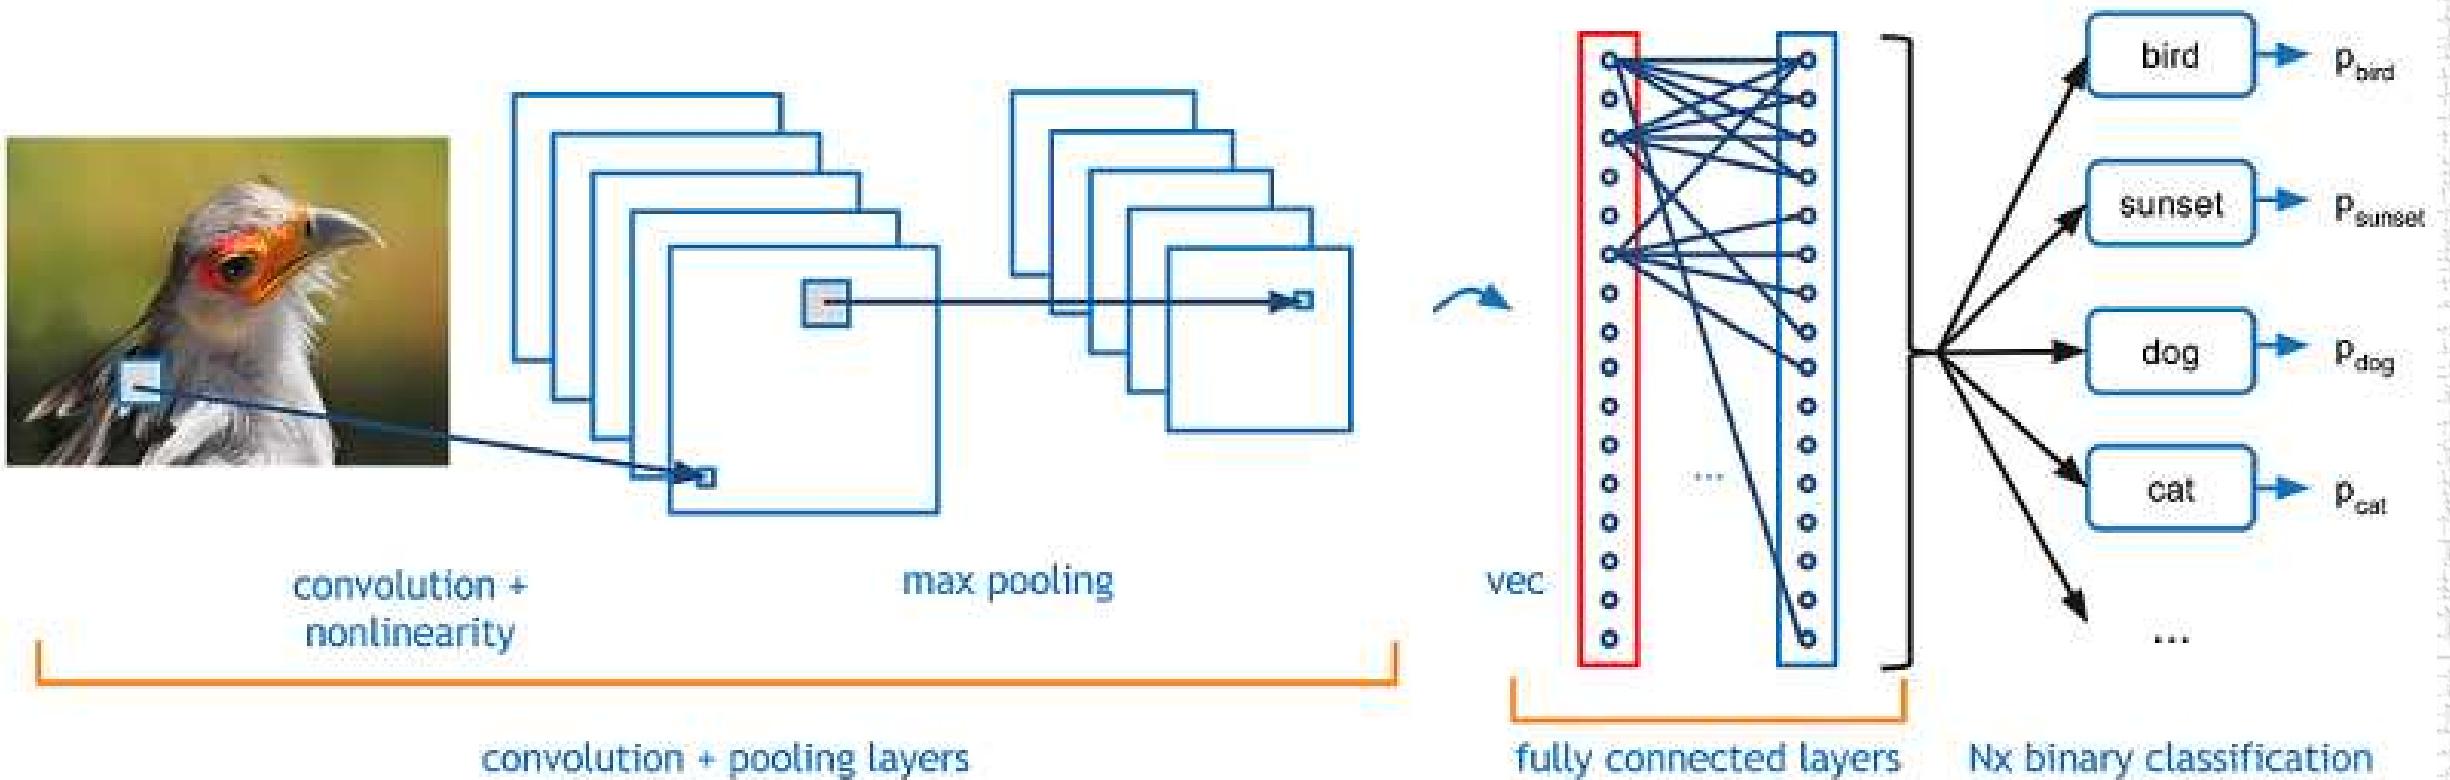


Nesne algılama problemi, bir görüntüde aynı anda birden fazla nesne sınıfının bulunabileceğini varsayımıştır.

Bunu iki tür problem gibi de görselleştirebiliriz, biri çoklu etiket sınıflandırması (bir görüntüde çoklu sınıf).

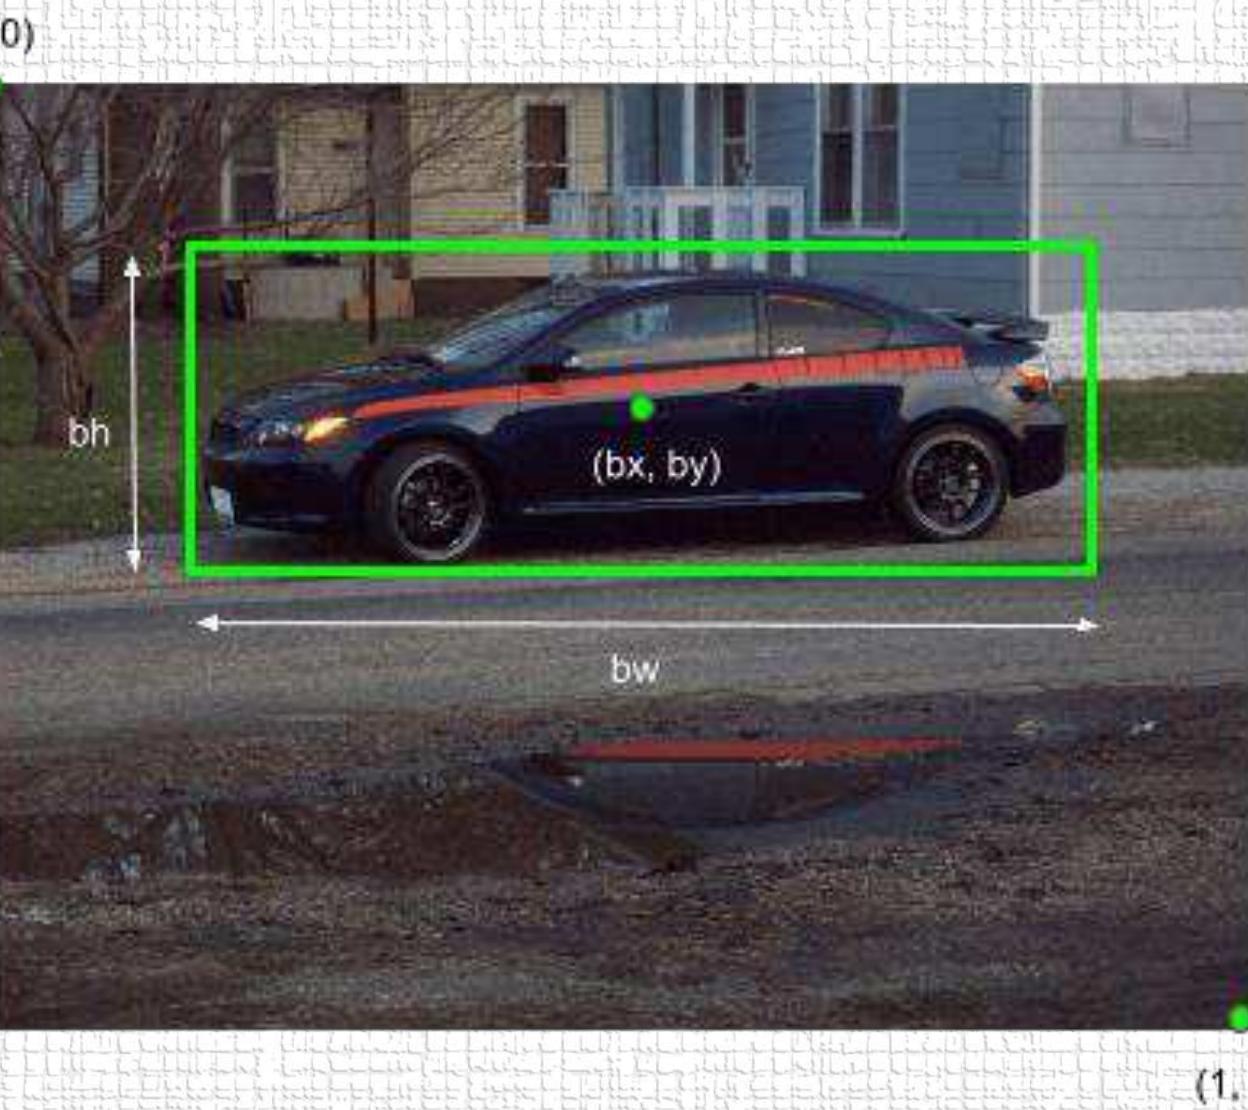
Sınırlayıcı kutunun koordinat değerlerini x, y, w, h cinsinden tahmin etmemiz gereken Bounding Box(Regresyon Problemi).

Bir görüntüde tek bir nesnenin bulunduğu durumu göstermektedir, ancak şekilde gösterildiği gibi bir görüntüde birden fazla nesne olsa bile algılamak mümkün olmalıdır.



Nesne Yerelleştirme

Nesne lokalizasyonunun görevi, bir görüntüdeki nesneyi ve sınırlarını tahmin etmektir. Nesne yerelleştirme ve nesne algılama arasındaki fark hemen göze çarpmaz. Basitçe, nesne yerelleştirme bir görüntüdeki ana (veya en görünür) nesneyi bulmayı amaçlarken nesne algılama tüm nesneleri ve sınırlarını bulmaya çalışır.

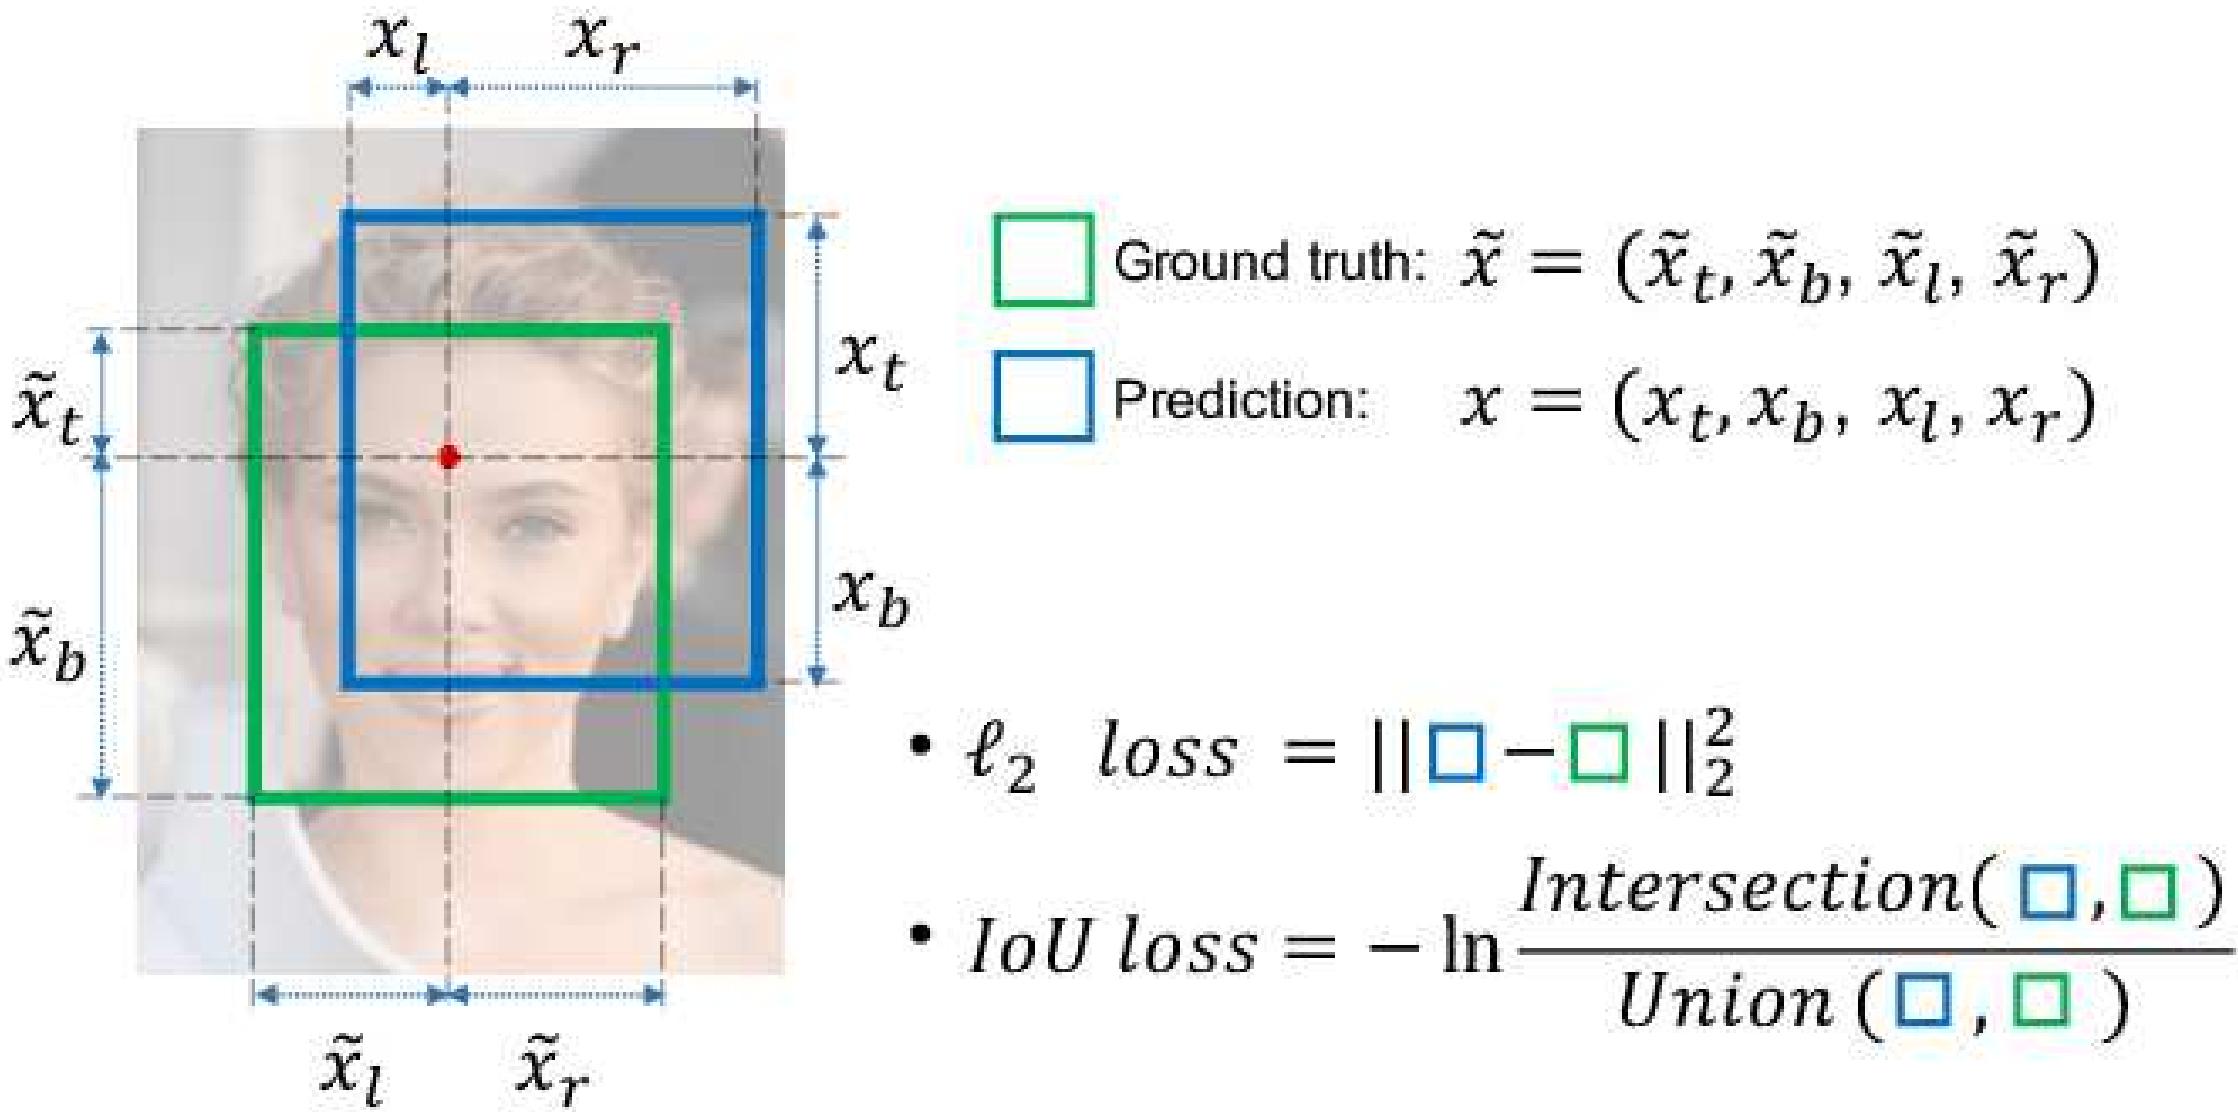


Bir görüntü sınıflandırması veya görüntü tanıma modeli, bir görüntüdeki bir nesnenin olasılığını tespit eder. Bunun aksine, nesne lokalizasyonu, görüntüdeki bir nesnenin konumunun belirlenmesini ifade eder. Bir nesne yerelleştirme algoritması, görüntüye göre bir nesnenin konumunun koordinatlarını çıkaracaktır. Bilgisayarla görmede, bir görüntüdeki bir nesneyi lokalize etmenin en popüler yolu, konumunu sınırlayıcı kutular yardımıyla temsil etmektir.

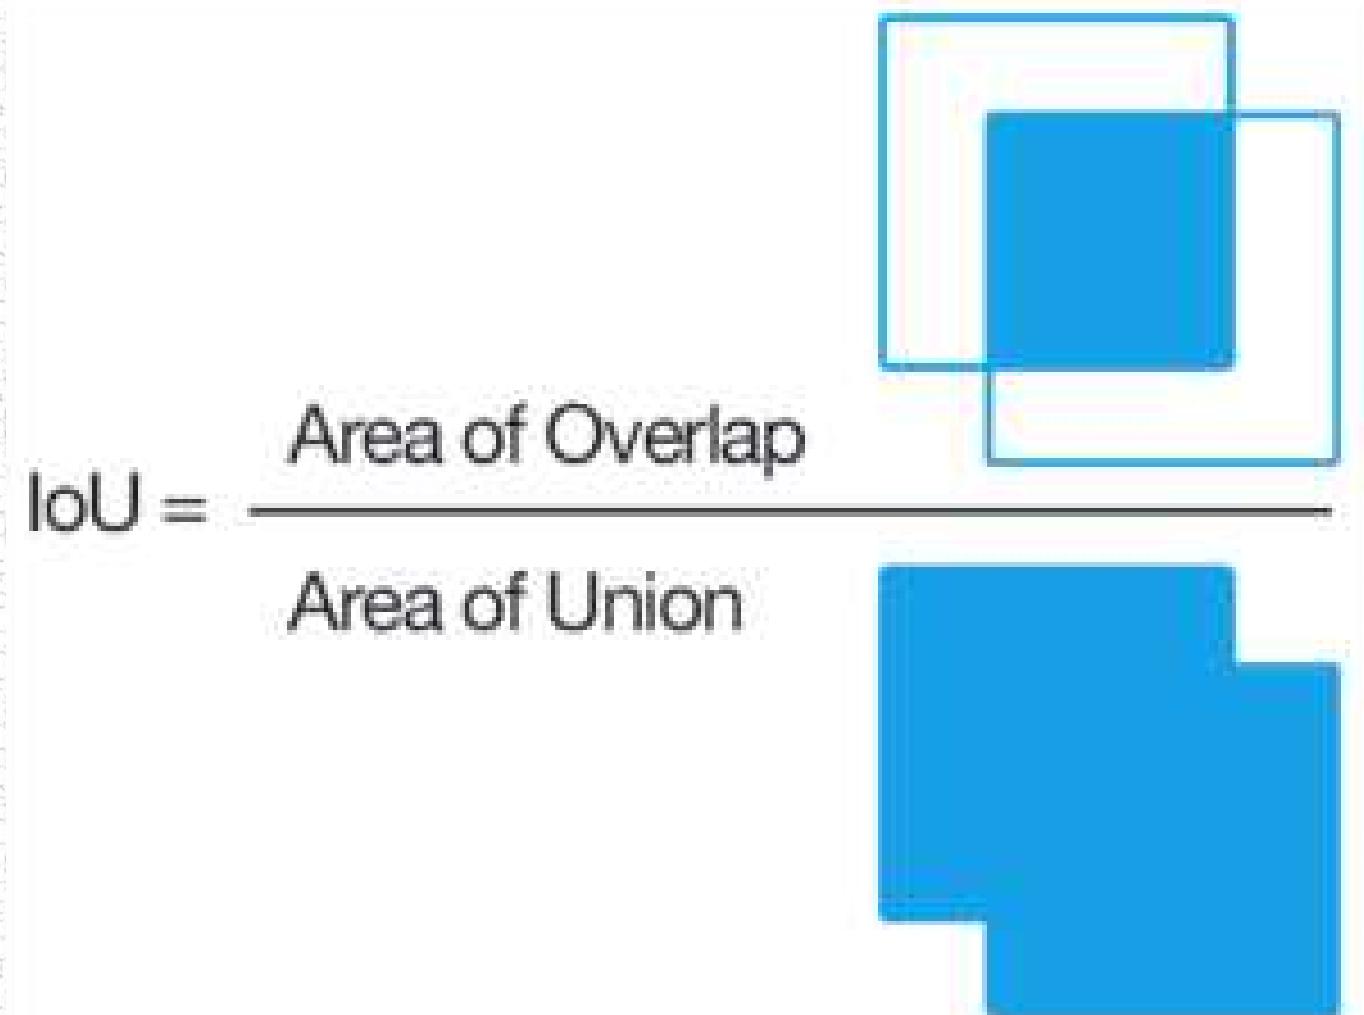
Bir Sınırlayıcı Kutu, aşağıdaki parametreler kullanılarak başlatılabilir:

- bx, by : sınırlayıcı kutunun merkezinin koordinatları
- bw : sınırlayıcı kutunun genişliği w.r.t görüntü genişliği
- bh : sınırlayıcı kutunun yüksekliği, görüntünün yüksekliği ile

- Bunu tahmin ederek, Ortalama-IOU'yu hesaplıyorlar ve Görüntüdeki nesneyi yerelleştiren sınırlayıcı kutuyu tahmin ediyorlar.



- IoU : Jaccard Index olarak da adlandırılan Intersection-Over-Union (IoU), Nesne Algılamada en yaygın kullanılan performans ölçütlerinden biri olarak kabul edilir.



- IoU, soldaki resimde gösterildiği gibi, hem tahmin edilen segmentasyon hem de kesin bilgi arasındaki örtüşme alanıdır ve tahmin edilen segmentasyon ile gerçek hikayen arasındaki birleşme alanına bölünür. Bu metrik, 0–1 (%0-100) arasında değişir; 0, çakışma olmadığını (çöp) ve 1, mükemmel örtüşen segmentasyonu (fat dub) belirtir.

Ortalama IoU : İkili (iki sınıf) veya çok sınıflı segmentasyon, görüntünün ortalama IoU'su her sınıfın IoU'su alınarak ve ortalaması alınarak hesaplanır.

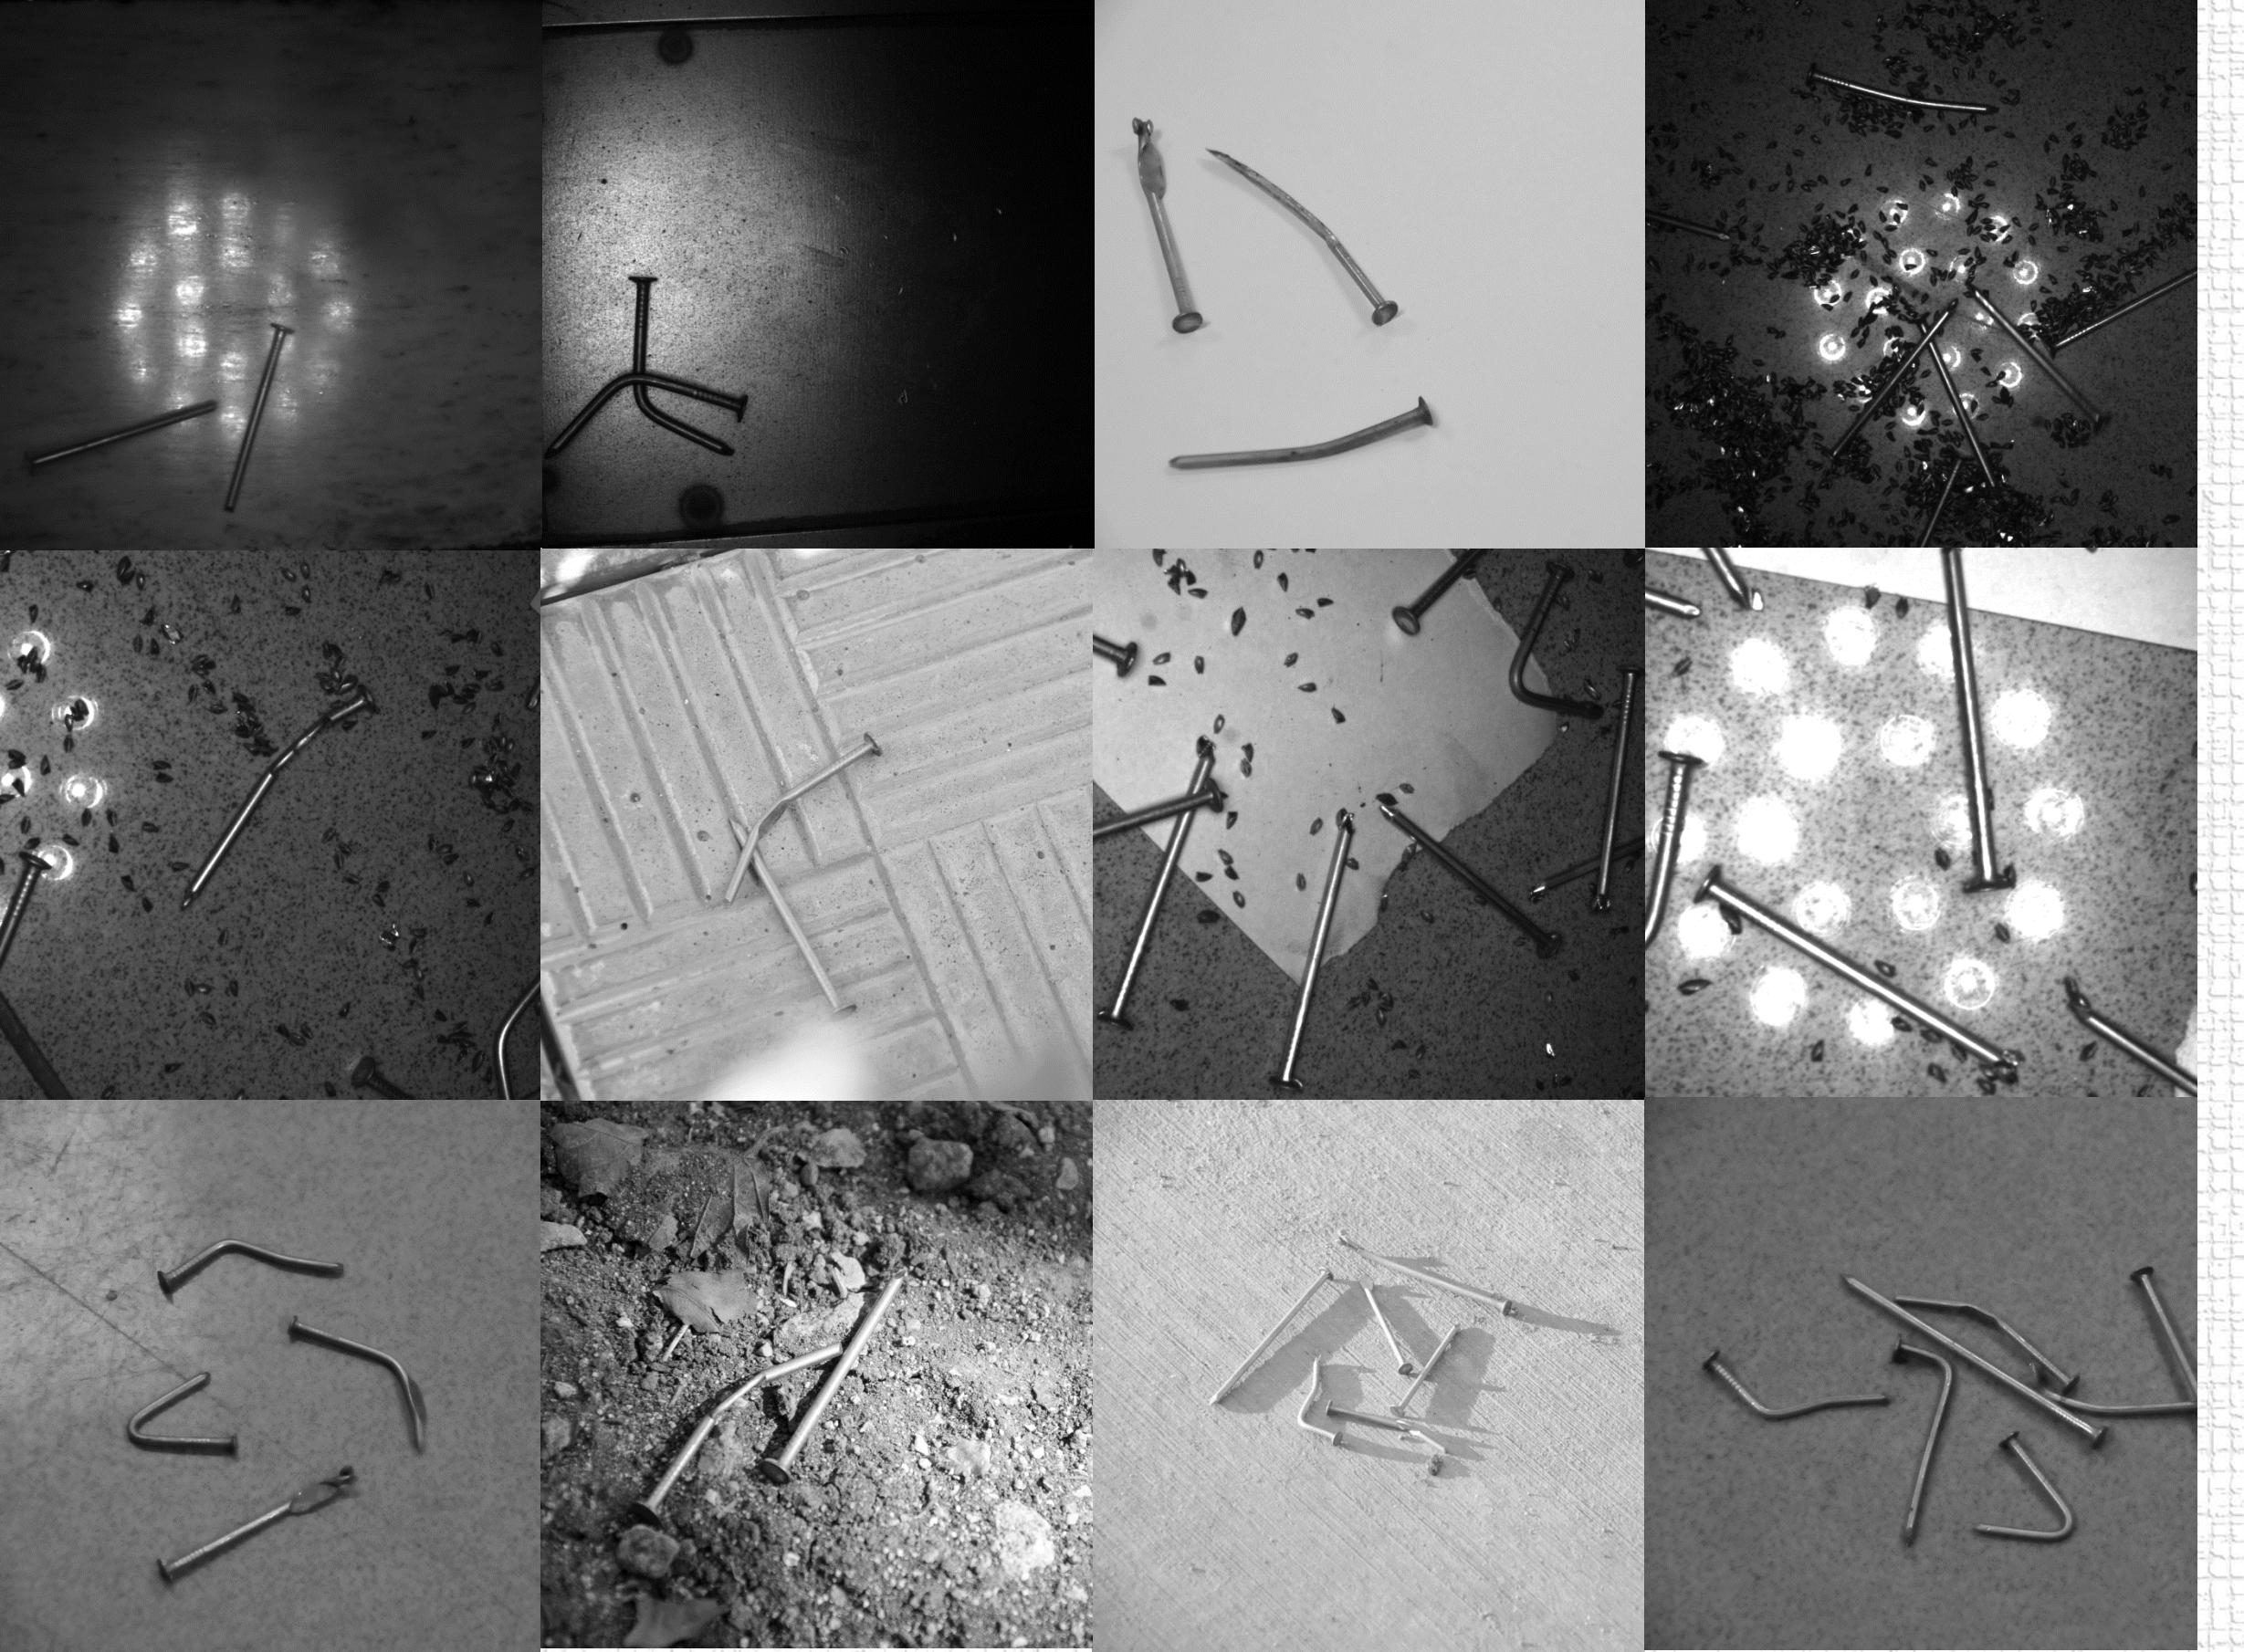
Veriseti Hazırlama Ve Etiketleme

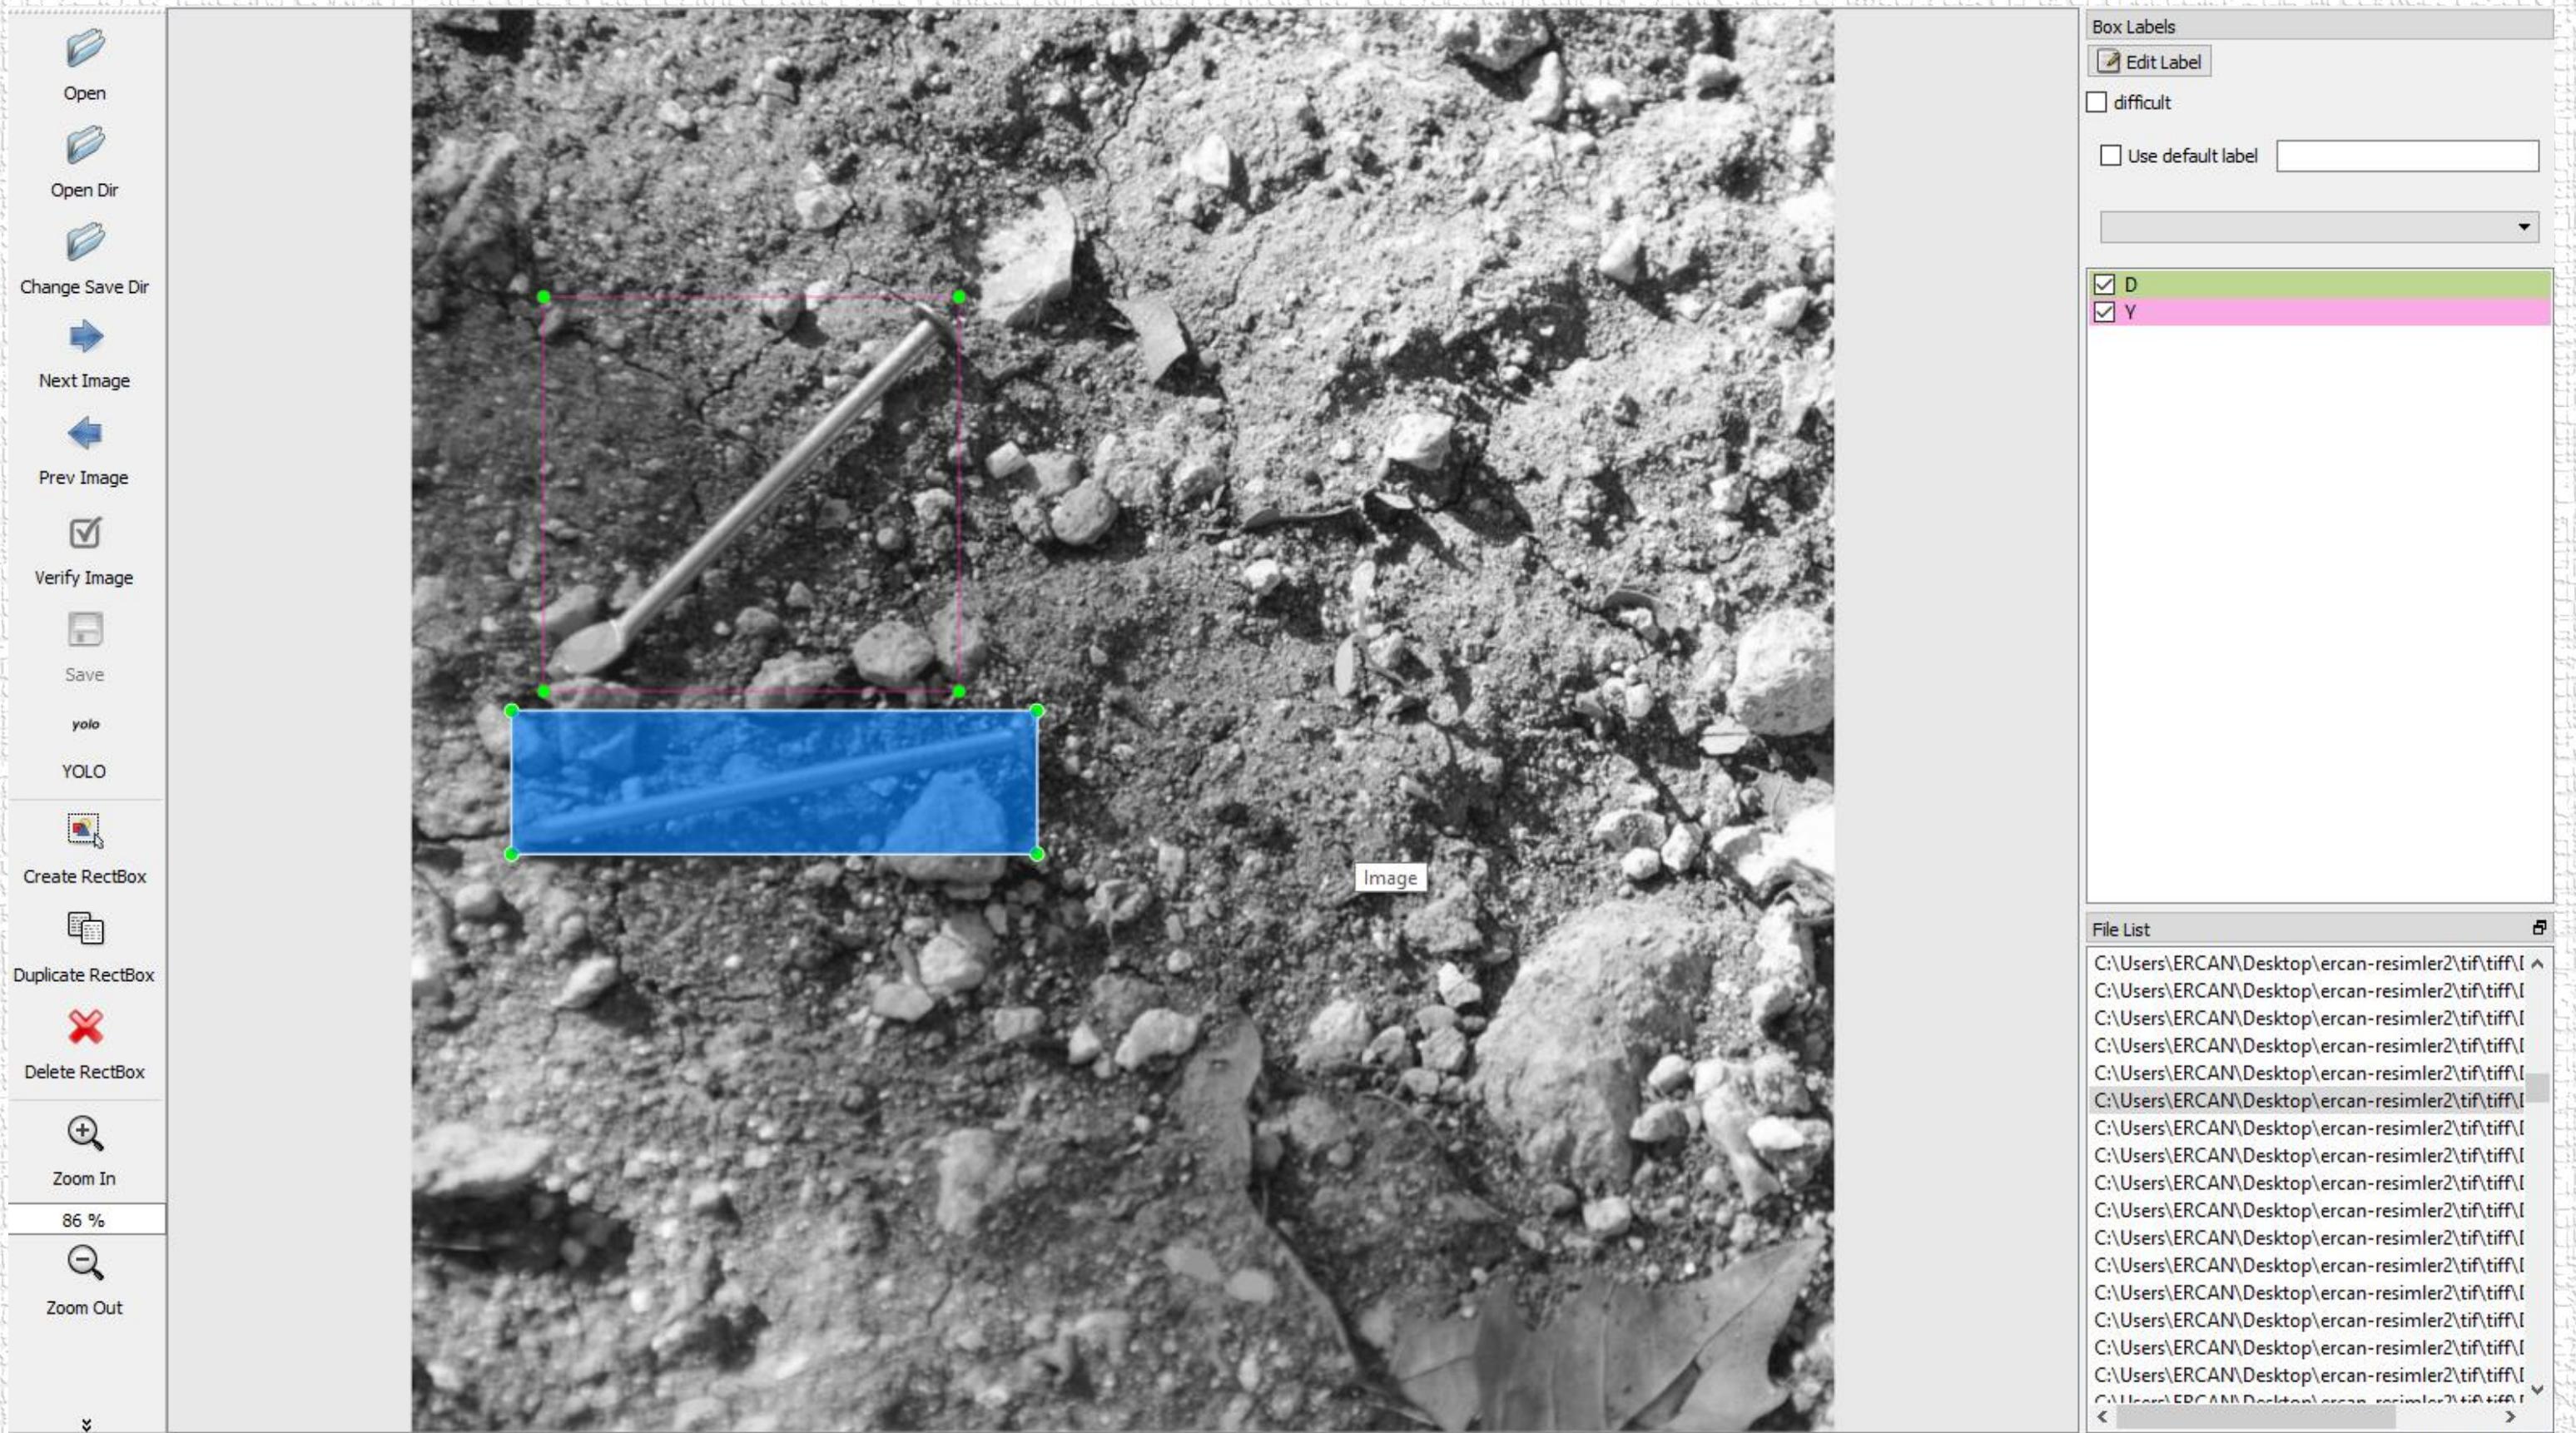
Hazırlama

- Veri seti başarının anahtarıdır.
- Veri seti hazırlarken açısal ve ortamsal farklılıklara dikkat edilmelidir.
- Aynı ortam ve açıdan çekim yapmak eğitim aşamasında aşırı öğrenmeye yol açar.
- Veri setinin eğitim kısmını gereğinden düşük tutmak az öğrenmeye yol açar.

Etiketleme

- Yapay zekaya objeyi veya objeleri öğretmeye yarayan bir yöntemdir.
- Objeyi lokalize ederken başlangıç ve bitiş noktaları seçilmelidir.
- Objeyi tam olarak ifade etmeyecek obje etiketlenmemelidir.





 DSC_0653.txt - Not Defteri

Dosya Düzen Biçim Görünüm Yardım

```
1 0.356445 0.528809 0.363281 0.055664  
2 0.378418 0.670898 0.331055 0.101562
```

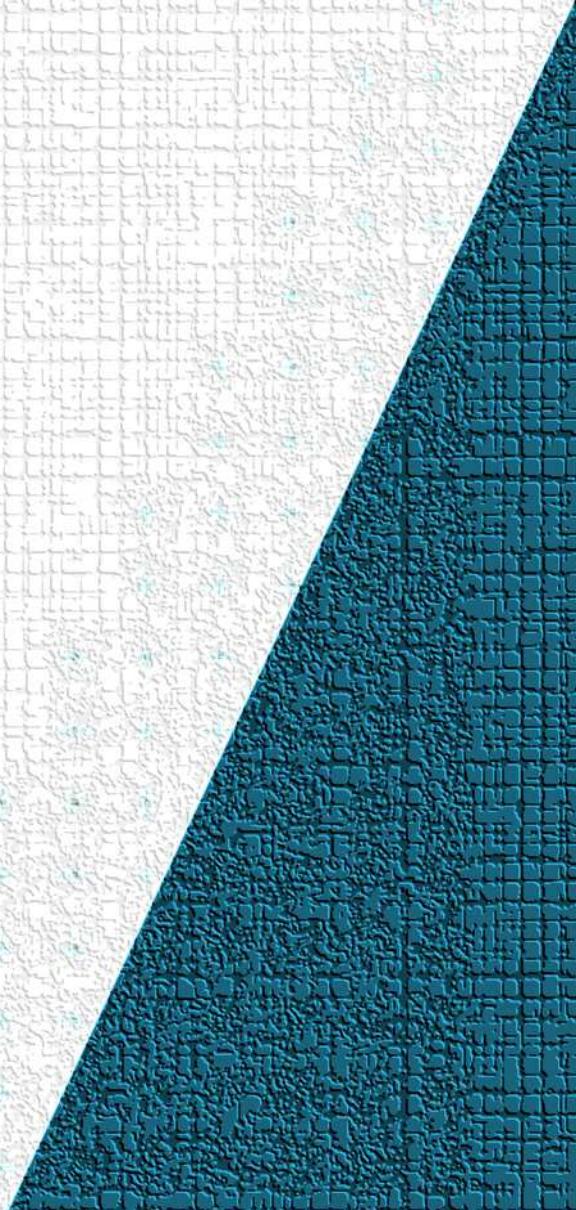
Eğitim

- Data seti kullanılacak yönteme göre uygun lokasyona uygun isimlerle yerleştirilir.
- Eğitim için konfigürasyon ayarlamaları yapılır. Konfigürasyon içerisinde resimlerin çoğaltırmalarından ekran kartı kullanım sayısına kadar ayarları yapılır.
- Eğitim başlatılır ve takibi sağlanır. Kullanılan yönteme göre modelin eğitim aşamaları grafiksel olarak takip edilebilir.
- Eğitim sonu belirlenen test data setiyle modelin başarısı test edilir, duruma göre döngü farklı konfigürasyonlar ile veya dataseti ile tekrarlanır.

Neden YOLO Neden Nesne Tespiti

- Sınıflandırma tek bir nesne tespiti ile çalışabilirken, nesne tespiti nesnelerin ne ve nerede olduğunu söyler.(Sadece kusurlu civi tespiti ve kusurlu ve kusursuz civi tespiti)
- YOLO, gerçek zamanlı olarak da çalışabilir ve yüksek doğruluk elde eder.
- YOLO, tahminlerde bulunmak için sınır ağından yalnızca bir ileri yayılım geçisi gerektirir.
- YOLO tespitlerinde sınırlayıcı kutularını çizer ve en doğru nesne yerelleştirmesini gerçekleştirir.
- YOLO ile tek bir CNN ile aynı anda birden çok sınırlayıcı kutu ve kutular için sınıf olasılıkları tahmin eder.
- Tam görüntü üzerinde çalışır ve eğitim esnasında algılama performansını optimize eder.

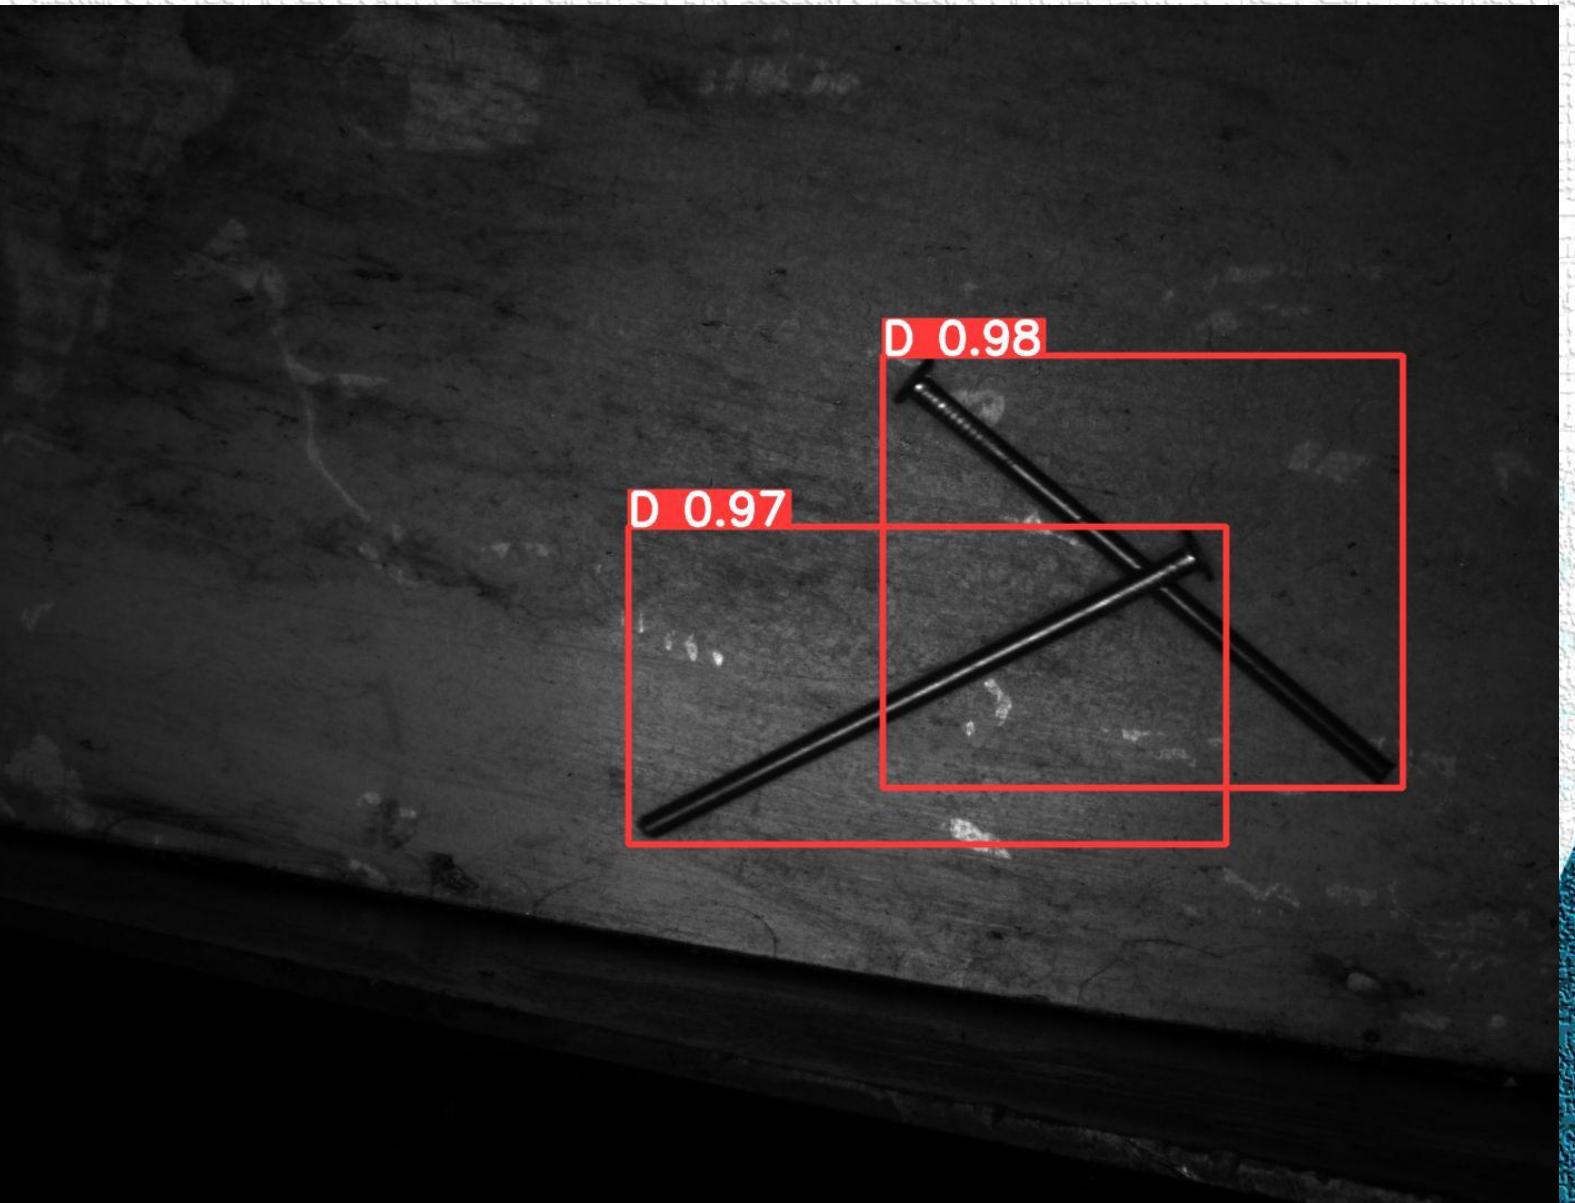
ÖRNEKLER



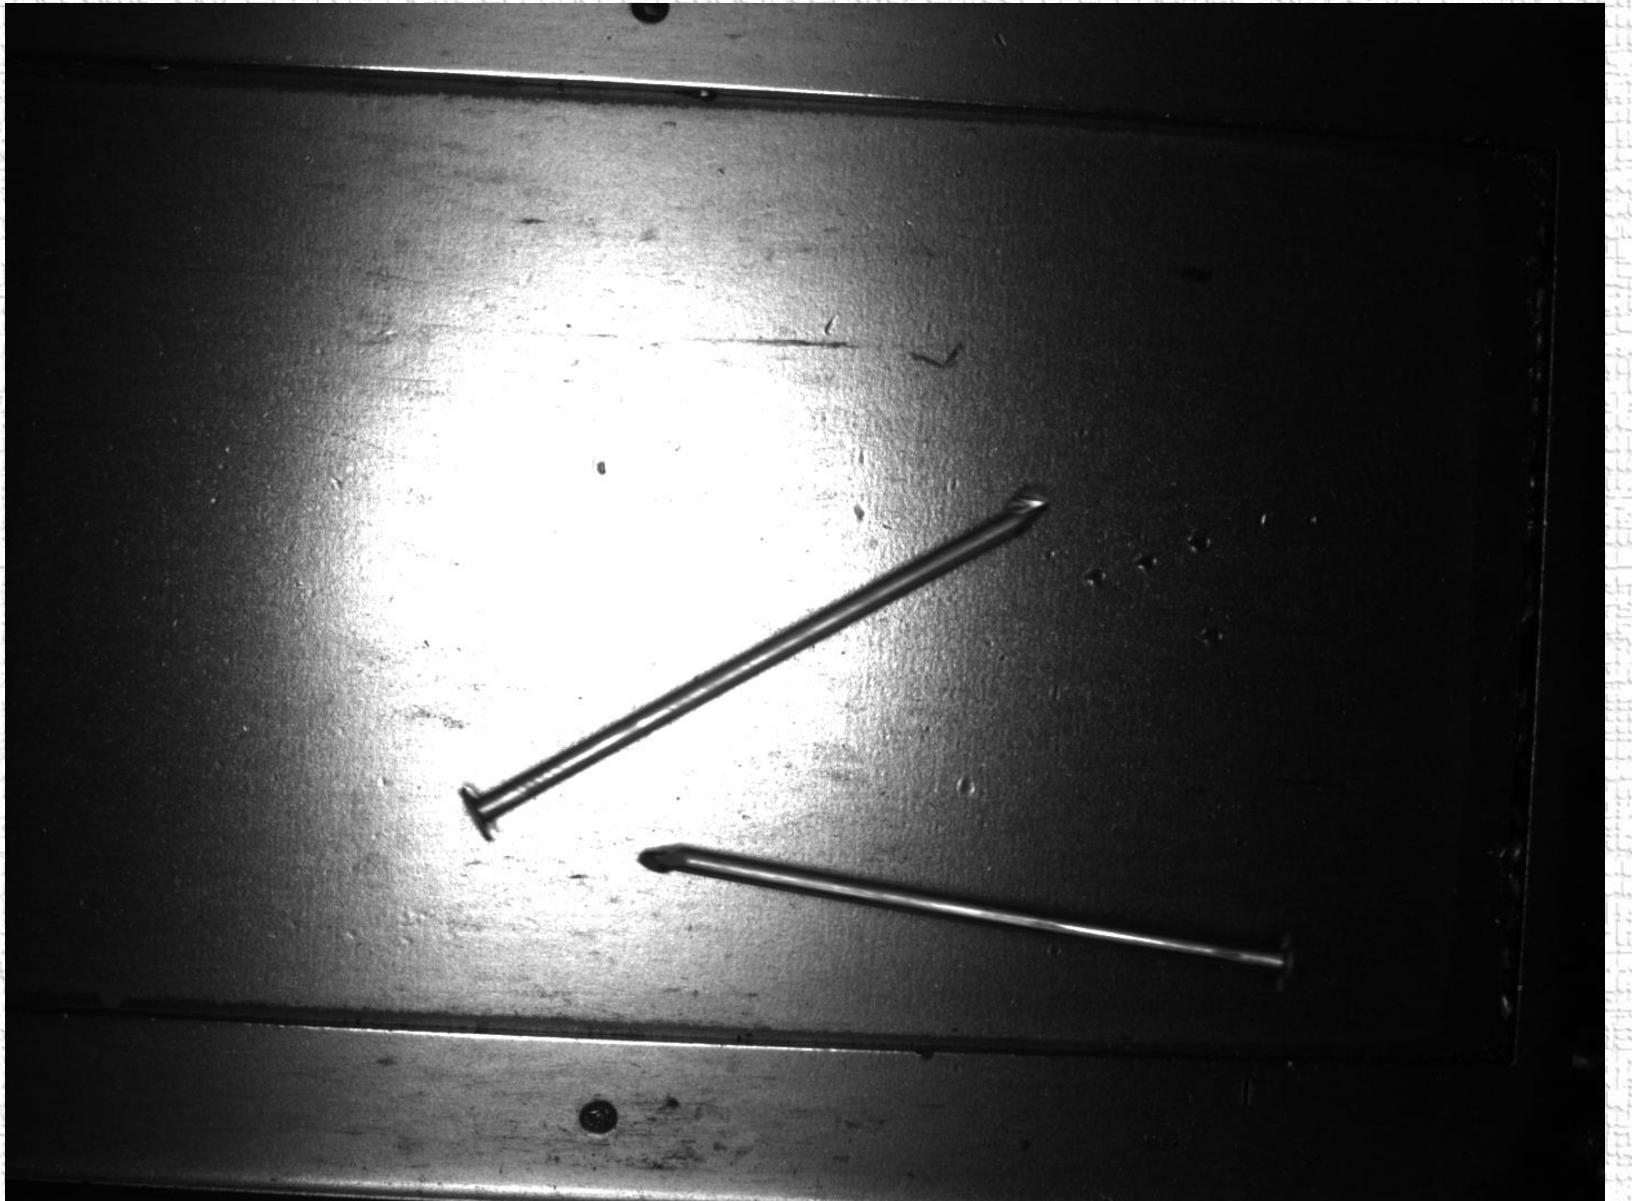
Gelen Veri



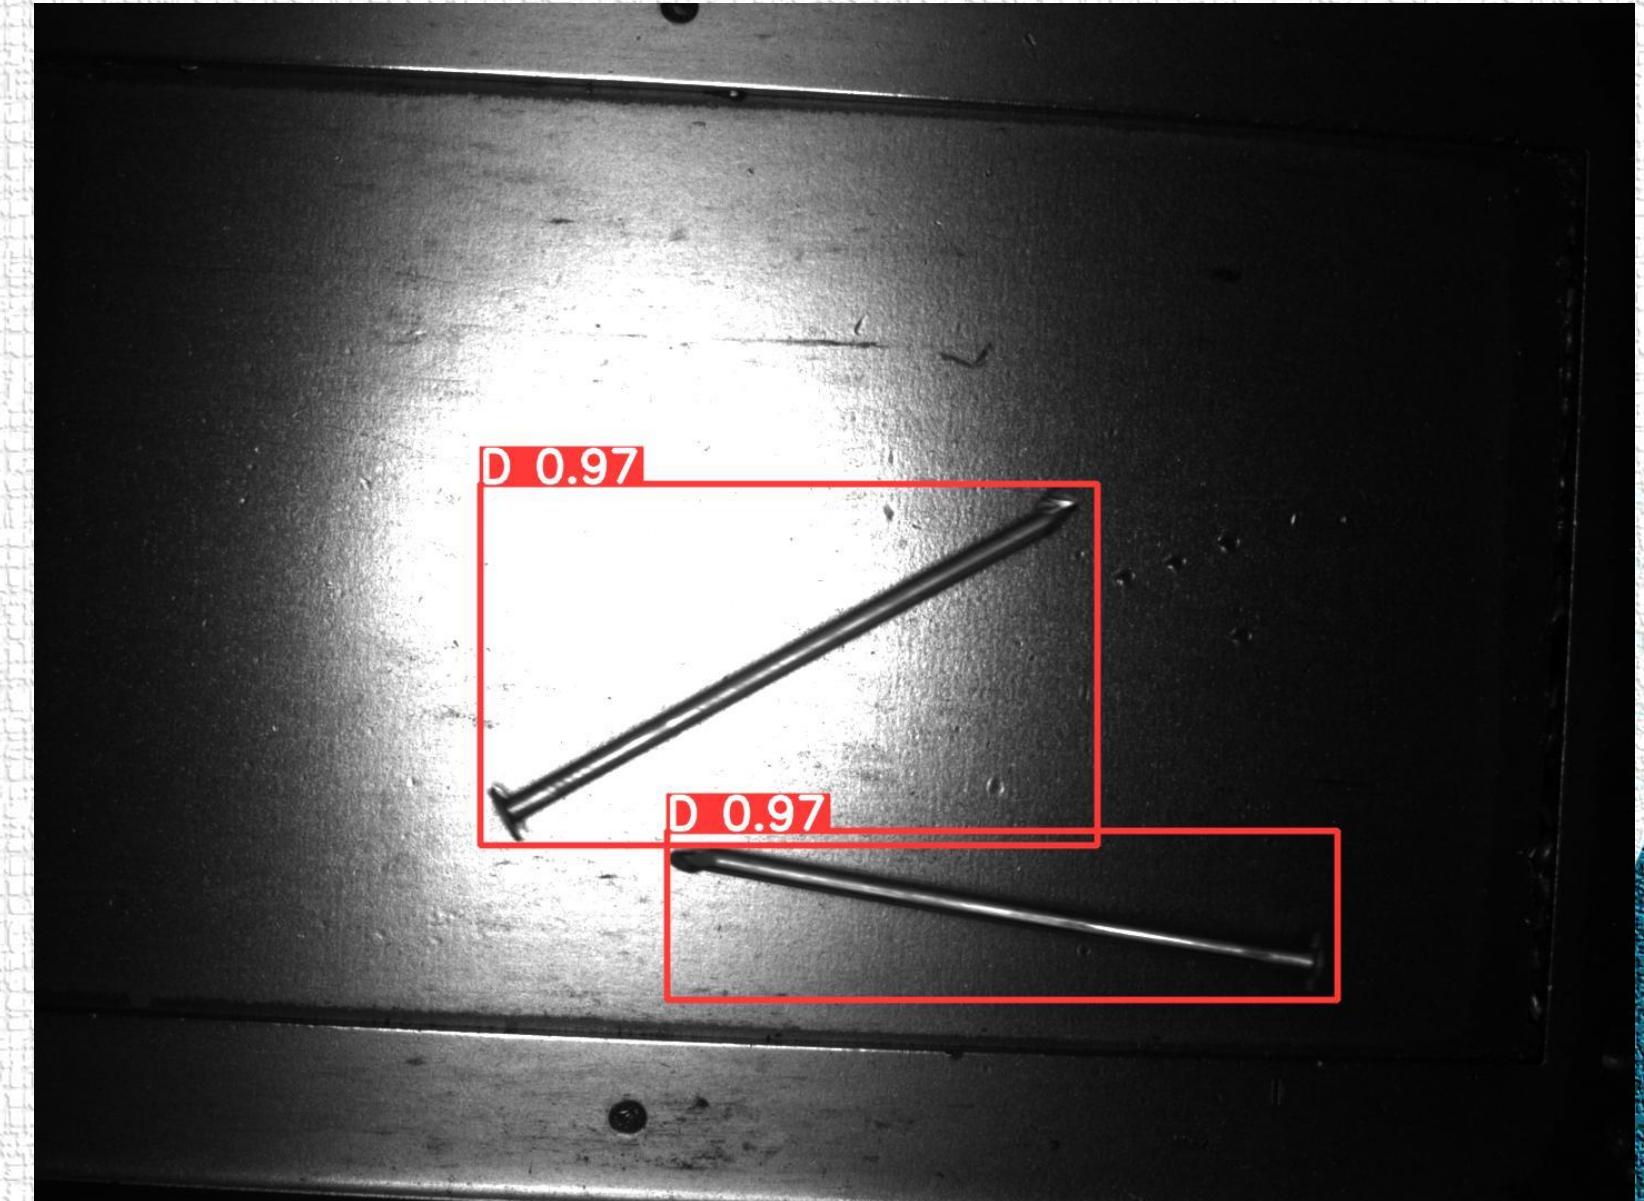
Sistem Çıktısı



Gelen Veri



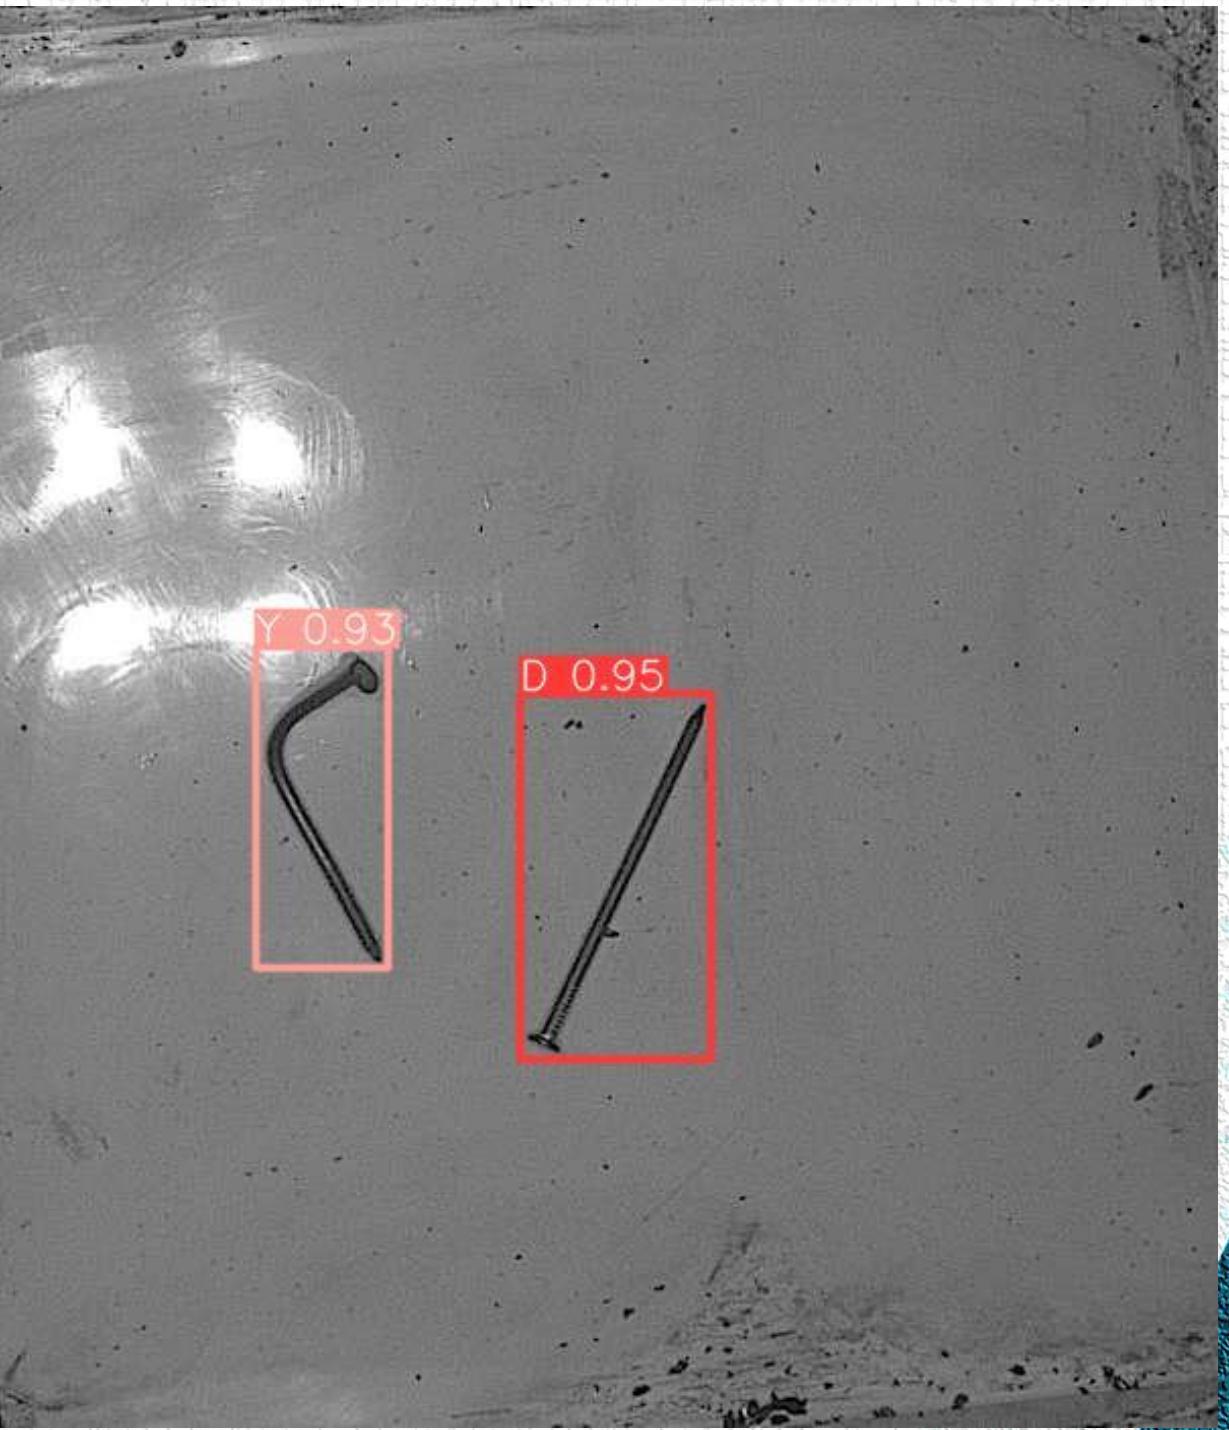
Sistem Çıktısı



Gelen Veri -



Sistem Çıktısı



Projenin Yenilikçi Yönü ve Ar-Ge Niteliği

Dünyada yapay zeka kullanarak kusurlu çivi tespiti yapan bir kurum bulunmamakta olup, kusurlu çiviyeye ait veriseti dahi bulunmamaktadır. Bu bağlamda öncü bir firmayız.

Kusurlu çivilerin oluşturduğu dizgi makinasının durması, hurda kaybı ve üretimi azaltmasın maddi olarak yıllık yaklaşık 80 ton, bu tonaja karşılık gelen 80.000,00 \$ gibi ticari kayıplar oluştururken, geliştirmiş olduğumuz yapay zeka modeliyle bu kayıptan büyük ölçüde kurtulmaktadır.

Sanayi 4.0 devrimine yeni proje olan CIVIDA ile güçlü bir adım atım desteklediğimizi tescillemiş bulunmaktayız.

Proje, bulut sistemler dahil olmak üzere izleme ve dağıtım gibi birçok farklı çalıştırma sistemine kolaylıkla adapte olabilmekte.

Projenin Beklenen Çıktı Ve Kazanımları

Sistemin aktif olarak çalışıp ve üzerine gelişim katedebilmesi en büyük kazanımlardan biri oldu. Son haliyle sistemi ürün haline getirme hedefimiz bulunmakta olup yapmış olduğumuz sistemin Dünya'da bir örneğinin bulunmaması bizin öncü olduğumuzu kanıtlamakta ve bize patentini alma hakkı doğurmuştur. Bu çerçevede sahip olduğumuz sistemin patent çalışmalarına başlanmıştır.

Kusurlu civilerin oluşturduğu dizgi makinasının durması, hurda kaybı ve üretimi azaltmasın maddi olarak yıllık yaklaşık 80 ton, bu tonaja karşılık gelen 80.000,00 \$ gibi ticari kayıplar oluştururken, geliştirmiş olduğumuz yapay zeka modeliyle bu kayıptan büyük ölçüde kurtulmaktadır.